

1

研究问题

VLM 真的在看吗

- 文本预训练让模型记住 Adidas 有三条纹、鸡有两条腿等常识。
- 论文修改熟悉图像，却只提出中性的计数或识别问题，没有对抗文本。
- 若模型仍回答标准事实，说明先验知识压过了视觉证据。

4

实验结果

先验知识占主导

- 五个 SOTA VLM 在原图上 100%，反事实图平均计数准确率仅 17.05%。
- 75.70% 回答落在偏差答案；修改图的 Y/N 识别准确率降至 25.11%。
- 小数量也失败：动物腿 2.12%、棋盘行列 2.26%、图案网格 22.44%。

2

VLMBias

人工审核的反事实集

- 1,392 张图覆盖动物、Logo、旗帜、棋类、棋盘、错觉与图案网格七个领域。
- 用图像编辑器或脚本增删标志元素，人工剔除含糊与低质量样本。
- 原图 sanity check 证明五个 VLM 都认识对象并知道标准数量。

5

因果线索

背景与过度思考

- 去掉熟悉背景后，准确率提升 21.09 点，偏差率下降 40.58 点。
- 增加推理 token 最初把准确率提高到约 40%，随后过度思考使表现下降。
- 工具使用越久越有帮助，但 o4-mini 因过度自信仅在 29.66% 问题上调用工具。

3

评估指标

准确率与偏差率

- Q1/Q2 要求客观计数；Q3 询问修改后的对象是否仍是原对象。
- 偏差率统计回答与记忆中的标准答案一致，而非与反事实真值一致的比例。
- 视觉编码器线性探针在腿部计数达 95.26%，说明视觉信号在语言融合前已经存在。

6

启示

先进行视觉落地再作答

- 熟悉视觉线索会激活语言先验，淹没已经被视觉编码器正确表示的感知信息。
- 大模型可能偏差更强；专门训练计数的模型提升到 36.02%，但仍不完善。
- 未来需校准不确定性、自动裁剪/缩放、异常检查和偏差感知视觉训练。

VLMBIAS 视觉语言模型偏差

视觉语言模型是有偏的

When Prior Knowledge Overrides Visual Evidence | ICLR 2026

熟悉的视觉背景会强烈触发记忆事实，使领先 VLM 忽略反事实细节，甚至在中性计数与识别问题上失败。

视觉偏差

反事实图像

计数