

1

研究问题

U-NET 是必需的吗

- 当 Transformer 统一其他领域时，扩散模型仍长期依赖卷积 U-Net。
- 论文检验接近标准的 ViT 能否作为去噪主干，并具有可预测的扩展规律。
- 架构复杂度用 Gflops 衡量，而不是只看参数量。

2

模型流程

VAE 潜变量到图像块 TOKEN

- 冻结 VAE 把 256 x 256 RGB 图像压缩为 32 x 32 x 4 潜表示。
- Patchify 把带噪潜表示转换成序列，p=2/4/8 控制 token 数。
- Transformer 同时预测噪声与对角协方差，再还原为潜空间布局。

3

条件机制

ADALN-ZERO 最优

- 比较条件 token、交叉注意力、adaLN 与恒等初始化的 adaLN-Zero。
- 时间步和类别嵌入在 adaLN-Zero 中生成缩放/平移及残差门控。
- 门控零初始化让每个 Block 初始为恒等映射，精度与计算效率均最佳。

DIT 扩散 TRANSFORMER

Scalable Diffusion Models with Transformers

The DiT Architecture and Scaling Study | ICCV 2023

用处理潜空间图像块的 Vision Transformer 替代扩散 U-Net，并证明通过模型规模或 token 数提升的前向 Gflops 能稳定预测图像质量。

DiT

潜空间扩散

规模扩展

4

扩展规律

计算量驱动质量

- S/B/L/XL 改变深宽；减小 Patch 会增加 token，却几乎不增加参数。
- Transformer Gflops 与 FID 的相关系数为 -0.93：模型计算越多，FID 越低。
- 增加采样步无法弥补弱模型；更大的 DiT 使用训练计算更高效。

5

实验结果

达到当时最先进

- ImageNet 256：无分类器引导下 DiT-XL/2 达 FID 2.27、IS 278.24。
- ImageNet 512：FID 3.04，优于 ADM 的 3.85；模型 Gflops 为 524.6 vs 1,983。
- DiT-XL/2 前向 118.6 Gflops，超过当时潜空间与像素空间 U-Net 扩散模型。

6

影响与局限

为何重要

- DiT 确立 Transformer 是简单、可扩展的扩散主干，并促进跨领域设计复用。
- 论文明确了三个稳健设计轴：Patch 大小、模型规模和条件 Block。
- 实验仅覆盖固定 VAE 的类别条件 ImageNet；文本、视频和更强自编码器留待后续。