

1

双重成因

起源与持续

- 预训练必须从大量可能文本中辨别有效表述；学习不完美时必然给错误分配概率。
- 后训练可教会拒答，但排行榜往往让猜测比“我不知道”更容易得分。
- 因此幻觉既是统计问题，也是由评测制度塑造的社会技术问题。

2

IIV 归约

把生成化为分类

- 定义 Is-It-Valid 二分类：判断一个看似合理的候选回答是有效还是错误。
- 对条件生成概率设阈值，就能把任意语言模型转成 IIV 分类器。
- $\text{幻觉} \geq 2 \times \text{IIV 错误}$

3

误差因素

事实为何学错

- 任意或罕见事实没有可压缩规律，对未见答案存在认识性不确定性。
- 训练集中只出现一次的事实比例可估计缺失概率质量，并给出错误率下界。
- 模型表达不足、计算难题、分布漂移与源数据错误还会进一步增加幻觉。

语言模型为何会幻觉

为什么语言模型会产生幻觉

Statistical Origins and Misaligned Evaluation Incentives | 2025

幻觉在预训练阶段源于普通的统计分类误差，又因主流二元评测奖励自信猜测、惩罚诚实表达不确定性而长期存在。

幻觉不确定性评测激励

4

评测陷阱

二元评分鼓励虚张声势

- 在 0/1 正确率下，拒答恒得 0；只要猜中概率大于零，猜测的期望得分就更高。
- 论文审查的 10 个主流评测中，9 个不给“我不知道”型回答实质分数。
- 当证据不足时，即使加入搜索、RAG 或更强推理，这种激励仍然存在。

5

缓解方案

显式置信阈值

- 明确阈值 t ：置信度高于 t 才回答；答对 +1，答错 $-t/(1-t)$ ，拒答 0。
- 应改造现有主流基准，而不只是另加少量“幻觉专项评测”。
- 由此可跨阈值审计行为校准，无需强迫模型输出数值概率。

6

范围与启示

重塑整个评测生态

- 理论聚焦“看似合理的错误陈述”与是否作答，不覆盖全部语用层面的不确定表达。
- 开放式回答、隐藏用户语境和不同错误严重程度仍需更细致的评分方式。
- 要真正降低幻觉，必须让主流评测不再惩罚可信且恰当的拒答。