

1

研究问题

低秩之间会互相干扰

- 复杂任务需要更高 LoRA 秩，但秩更新相关会浪费容量并可能造成训练不稳。
- MoE-LoRA 虽拆分专家，却需要显式可训练路由器，且每个专家内部仍混合多个秩。
- 合并多个任务适配器时，还会出现破坏性的任务间干扰。

2

仿生设计

随机投影 + 胜者全得

- 果蝇嗅觉回路先用稀疏随机连接扩展输入，再只保留强响应神经元。
- FlyLoRA 冻结稀疏 A，计算 Ax ，并激活与最大幅值对应的 k 个 B 的秩 1 列。
- 无损失偏置负责均衡负载；A 同时承担下投影与路由器两种角色。

3

理论机制

用稀疏性解耦

- 稀疏随机 A 近似保持样本间距离，使相似输入获得一致路由。
- k^2/r^2
- 不同任务的随机投影近似正交，使合并后的适配更新尽量互不干扰。

FLYLoRA 果蝇启发低秩适配

FlyLoRA：隐式逐秩专家混合

Implicit Rank-Wise Mixture-of-Experts for Efficient Adaptation | NeurIPS 2025

借鉴果蝇嗅觉回路，冻结稀疏随机 LoRA 下投影，并把其 Top-k 激活直接作为逐秩路由，从而同时降低任务内与任务间干扰。

LoRA

隐式 MoE

模型合并

4

计算效率

更大容量，更少激活参数

- 总秩 $r=32$ 提供宽广子空间，但每个 token 仅激活 $k=8$ 个逐秩专家。
- 冻结 A 省去优化器与激活梯度开销；取消 W_g 又消除了路由参数。
- 实验中投影幅值最大的 25% 维度承载了 80% 以上激活能量。

5

实验结果

单任务与多任务都提升

- 在 Llama-3.1-8B 上仅激活 0.13% 可训练参数，却在四个领域全面超过基线。
- MMLU 40.88、ScienceQA 94.15、GSM8K 58.76、HumanEval pass@1 36.88。
- 简单合并多任务适配器后保留更多能力；冻结 A 对鲁棒性尤其关键。

6

意义与局限

用几何替代路由

- 固定随机几何既能替代学习式路由，又天然创建较分离的任务子空间。
- 当前主要验证四个基准与两个 7-8B 主干，扩展性仍需更广验证。
- 随机投影只能降低干扰，不能保证所有场景都语义专门化或无损合并。