

1

研究问题

去噪器其实在预测噪声

- 现代扩散模型通常直接输出 epsilon 或速度，而不是最终所需的干净样本  $x_0$ 。
- 在潜空间中问题不明显，但在原始像素中，这要求模型重建完整的高维含噪量。
- 因此像素生成常依赖稠密网络、小 patch、tokenizer、预训练或辅助损失。

2

流形视角

数据低维，噪声高维

- 自然图像近似位于高维像素空间中的低维流形。
- 噪声和速度位于流形外，信息遍布全部环境维度。
- 瓶颈即使无法复现完整噪声向量，也能丢弃噪声并预测流形上的数据。

3

JiT 架构

只有图像 TRANSFORMER

- 直接在原始像素上使用普通 ViT：256 分辨率用 patch 16，512 用 patch 32。
- 直接  $x$  预测无需 tokenizer、卷积、GAN/感知损失、蒸馏或自监督预训练。
- 窄输出瓶颈不仅不伤性能，反而可能有益，与经典流形学习相呼应。

JiT 回归去噪本质

回归基础：让去噪模型真正去噪

Just image Transformers for Pixel-Space Generation | 2026

直接预测干净图像。自然图像位于低维流形附近，而噪声充满高维环境空间，因此看似容量不足的 Transformer 也能有效去除原始像素噪声。

$x$  预测

像素扩散

流形假设

4

参数化机制

输出空间不等于损失空间

- $z_t = t x + (1-t) \epsilon$ ;  $v = x - \epsilon$
- 网络可直接输出  $x$ ，再通过代数转换使用  $x$ 、 $\epsilon$  或  $v$  空间损失训练。
- 固定同一损失，仅把直接输出从  $v$  改为  $x$ ，即可证明关键在网络参数化。

5

实验结果

大 PATCH 也能工作

- 在高 patch 维度下  $\epsilon/v$  预测可能灾难性失败，而  $x$  预测依然稳定。
- ImageNet 512：JiT-H/32 的 FID 为 1.94，JiT-G/32 为 1.78，且无预训练或额外损失。
- JiT-B/32 仅用 26G FLOPs 即达 FID 4.02，模型放大后质量平滑提升。

6

意义与局限

自包含生成范式

- 该结果把“直接预测什么”与扩散概率公式明确区分开。
- 原始数据上的“Diffusion + Transformer”有望迁移到难做 tokenizer 的领域。
- 流形假设只是近似；证据主要来自 ImageNet，采样仍使用 50 步 ODE。