

1

问题重构

从符号序列回到图像

- ARC 中的反射、对称、重力和复制等变换，本质上具有视觉与物理属性。
- 以往多把网格序列化，交给 LLM 或循环推理模型处理。
- VARC 把输出网格视为逐像素分类，并用可学习任务 token 提供条件。

2

视觉先验

画布与二维结构

- 把离散网格随机平移、缩放后放到 64 x 64 画布，并把颜色索引嵌入连续向量。
- 2 x 2 patch 带来局部性与平移不变性，二维 RoPE 保留空间结构。
- 画布产生指数级颜色组合，迫使模型学习空间规律而非记忆有限符号。

3

两阶段学习

离线训练 + 逐任务 TTT

- 从零联合训练 400 个 ARC-1 任务，并为每个任务加入 1000 对 RE-ARC 样本。
- 面对未见任务时，从离线模型出发，只用其 2-4 个示例独立微调。
- 翻转、旋转与颜色置换形成辅助任务，每个辅助任务拥有独立嵌入。

VARC 视觉抽象推理

ARC 本质上是一个视觉问题！

Vision-Centric Abstract Reasoning from Pixels | 2025

把 ARC 谜题视为少样本图像到图像翻译；视觉先验、逐任务测试时训练与多视图投票，使小型 ViT 泛化到未见抽象变换。

ARC视觉推理测试时训练

4

推理流程

510 个视觉视图

- 对随机缩放与平移视图运行模型，把映射到同一网格位置的像素概率取平均。
- 对 510 个视图进行整张网格精确多数投票，保留前两种答案计算 pass@2。
- 完成适配后，推理是一次前馈图像变换，而不是循环思维链。

5

实验结果

小模型接近人类 ARC-1

- 18M ViT 在 ARC-1/ARC-2 达 54.5%/8.3%；视觉先验较朴素基线提升 27.7 点。
- 与 55M U-Net 集成后 ARC-1 达 60.4%，接近论文引用的人类平均 60.2%。
- 超过从零训练的 HRM/TRM，参数量又比主流 LLM 系统小几个数量级。

6

意义与局限

推理应融合多模态

- 注意力图和任务嵌入展示了无语言标签学得的复制、射线、调色板与语义聚类。
- 集成模型 ARC-2 仍仅 11.1%；510 视图及每任务约 70 秒 TTT 增加成本。
- 视觉路线与语言推理互补，未来可加入更强视觉先验和预训练。