

1

研究问题

PRENORM 信息稀释

- 标准残差让每一层都接收所有早期输出的单位权重总和。
- 在 PreNorm 下隐藏状态幅值随深度增长，新层贡献被稀释，早期信息也被埋没。
- 只递归访问上一状态，无法选择性取回某个具体早期表示。

2

完整 AttnRes

沿深度做 SOFTMAX

- 把词嵌入和每个早期层输出视为深度维度上的键和值来源。
- 每层只增加一个可学习伪查询，归一化键后得到随输入变化的权重。
- $h_l = \sum_i \alpha_i v_i; \sum \alpha_i = 1$

3

分块 AttnRes

可规模化实现

- 把 L 层分成 N 块，块内仍用普通残差，块间只对摘要表示做注意力。
- 显存与跨流水级通信从 $O(Ld)$ 降到 $O(Nd)$ ，同时保留大部分收益。
- 跨级缓存与两阶段在线 Softmax 推理消除重复传输并摊薄计算。

ATTNRES 深度注意力残差

Attention Residuals: 让残差学会选择

Learned Softmax Retrieval across Network Depth | 2026

用对早期层输出的输入相关 Softmax 注意力替代均匀残差相加，使每层按需检索深度信息，同时抑制隐藏状态随深度无界增长。

残差连接

深度注意力

规模扩展

4

学习到的行为

可选择的跨层捷径

- 权重总体偏向相邻层，但持续保留嵌入并偶尔远距离回看，形成学习式跳连。
- 注意力层前使用更宽的深度上下文，MLP 前则更依赖近期状态。
- 分块聚合限制输出幅值增长，并让梯度更均匀地分布在不同深度。

5

实验结果

等效 1.25 倍计算优势

- 分块 AttnRes 可匹配多用 1.25 倍训练计算的普通残差基线。
- 48B 总参数/3B 激活的 Kimi Linear 在 1.4T token 上训练后，全部任务提升。
- GPQA 36.9↗44.4、Math 53.5↗57.1、HumanEval 59.1↗62.2。

6

开销与意义

注意力的第二条轴

- 训练开销很小，推理延迟增加不足 2%；约 8 个块即可恢复大部分收益。
- AttnRes 把深度方向的固定线性残差混合推广为 Softmax 检索。
- 完整访问仍需 $O(Ld)$ 显存；块粒度与超深部署仍待研究。