

1

核心问题

特征能否多于神经元

- 机制可解释性常希望每个神经元对应一个人类可理解特征。
- 真实模型却存在多义神经元，说明特征未必与神经元坐标轴对齐。
- 论文研究在表示维度有限时，网络何时会把多个特征打包在一起。

2

玩具模型

稀疏特征自编码器

- 输入由独立、重要性和稀疏度可调的特征组成，每次只激活一部分。
- 线性瓶颈接 ReLU，用少于输入特征数的隐藏维度重建这些特征。
- $\hat{x} = \text{ReLU}(W^T W x + b)$

3

核心结果

叠加是一种容量经济学

- 特征稠密时，最优方案会把正交维度分配给最重要的特征。
- 特征稀疏时，非正交表示可让大量特征共享同一组维度。
- ReLU 去除大量负向串扰；剩余干扰的代价仍低于彻底丢弃特征。

叠加表征

Toy Models of Superposition

叠加表征的玩具模型

How Networks Store More Features Than Dimensions | 2022

当有用特征足够稀疏时，网络可把它们放在非正交方向上，用少于特征数的维度进行叠加表示，再靠非线性过滤干扰。

叠加多义神经元可解释性

4

表示几何

多面体与对跖对

- 特征方向形成几何打包：对跖对、三角形、多边形及高维多面体。
- 每个特征占有分数化有效维度，取决于与邻近特征的夹角和干扰。
- 改变稀疏度或重要性，会在单义与叠加方案间产生离散相变。

5

叠加计算

特征是方向而非神经元

- 自然的表示单位通常是激活空间中的方向，而不是单个神经元。
- 当非线性门控能区分同时激活的组合时，网络可直接在叠加特征上计算。
- 相关或互斥特征会改变最优几何，互斥特征尤其适合高效共享维度。

6

可解释性启示

玩具模型不是现实全貌

- 多义性可能是合理的容量权衡，而非训练失败。
- 逐神经元解释会漏掉分布在多个方向上的特征，稀疏特征方法更匹配。
- 模型极度理想化；真实 Transformer 还有依赖、层级特征与复杂计算。