

1

威胁模型

语言本身就是攻击面

- 安全对齐在不同语言间并不均衡；罕见、压缩、修辞间接的表达容易绕过熟悉模式。
- 古文具有多义、用典、象征与嵌套句法，可隐藏敏感意图。
- 研究对象是闭源模型的自动化黑盒红队测试，而非白盒梯度攻击。

4

评估流程

翻译、过滤、裁判

- 两阶段模块先把古文响应统一翻译成英文再评分。
- 关键词检测结合 GPT-4o 语义意图裁判，并辅以人工复核。
- 指标包括攻击成功率、毒性分数和对受测模型的平均查询数。

2

策略空间

八个提示维度

- 每个候选组合角色身份、行为引导、机制与隐喻映射。
- 表达风格、知识关系、上下文设定和触发模式组成完整笛卡尔积。
- 生成器把原始有害请求和一个策略点映射为古文对抗提示。

5

实验结果

高成功率、低查询数

- 在 50 条 AdvBench 上，对六个目标模型均报告 100% ASR。
- 在 CLAS 与 StrongREJECT-small 上约为 98.3–100%，平均仅需 1.12–2.38 次查询。
- Claude-3.7 消融：纯古文 18%，加策略空间 60%，再加搜索达到 100%。

3

CC-BOS 搜索

果蝇启发优化

- 嗅觉搜索做步长衰减的局部扰动，视觉搜索把种群推向当前最优候选。
- 停滞时用重尾柯西突变跳出局部最优。
- 哈希去重避免重复查询；种群 5、最多 5 轮，使黑盒预算较低。

6

安全启示

防御必须跨语言泛化

- Llama-Guard 输入/输出双过滤会显著降低 ASR，但 CC-BOS 仍是测试中最强攻击。
- 结果暴露跨语言覆盖缺口，需要语义级、多语言、可自适应的防御。
- 指标部分依赖自动裁判；闭源模型版本会变化，方法本身也存在滥用风险。

CC-BOS 古文越狱红队测试

晦涩但有效：古文越狱提示优化

Classical Chinese Jailbreak Optimization via Bio-Inspired Search | ICLR 2026

古文能压缩并模糊恶意思图；CC-BOS 把这一攻击面系统化为八个提示维度，再用果蝇启发的黑盒优化器自动搜索。

越狱攻击

古文

安全红队