

1

统一诊断

多种伪影，同一根因

- 标签、文本与自监督 ViT 都会出现错位、注意力缺失或高范数 token。
- Registers 能消除高范数，却无法恢复语义定位，说明高范数只是症状。
- 论文提出根因是懒惰聚合：全局语义通过背景 token 形成捷径。

2

分析探针

PATCH SCORE + POINT-IN-BOX

- Patch Score 是 CLS 与 patch 的相似度，高值应表示局部内容与全局语义一致。
- Point-in-Box 衡量最高分 patch 是否位于标注前景框内。
- ViT 从训练早期就给背景高分，而同等 ConvNet 的前景定位更好。

3

形成机制

粗粒度监督 x 全局混合

- 图像级标签无法指出哪个 patch 真正相关，且背景数量远多于前景。
- 全局自注意力把物体信息扩散到背景 token，形成容易利用的分类捷径。
- 遮掉一半以上高分 patch 几乎不伤性能；遮低分 patch 则准确率崩溃。

LAST-ViT 修复懒惰聚合

视觉 Transformer 需要的不只是 Registers

Diagnosing and Fixing Lazy Aggregation in ViTs | 2026

ViT 的多类伪影来自同一根因：全局注意力让大量背景 patch 成为图像级语义捷径；频率引导的选择性聚合把 CLS 重新锚定到前景证据。

ViT 伪影

懒惰聚合

稠密特征

4

LaSt-ViT

频率引导选择

- 沿通道对每个 patch 特征做低通滤波，比较滤波前后表示的稳定性。
- 假设前景语义在通道上更稳定，据此选择或投票出信息性 patch。
- 只把被选特征聚合到 CLS，限制背景影响。

5

实验结果

三类监督、12 个基准

- LazyStrike 在三类监督 ViT 上同时消除高范数和 Patch Score 伪影。
- CLIP-B/16 零样本 VOC mIoU 49.0↗75.0；CLIP-L/14 为 17.1↗72.4。
- F-ViT-B 新类 COCO AP50 17.5↗33.3；DINO 物体发现 CorLoc 达 64.4/67.6/51.6。

6

意义与局限

不只是加 REGISTER TOKEN

- 修正聚合后，全监督 ViT 也会涌现此前主要见于自监督模型的分割能力。
- 前景通道稳定性仍是启发式假设，Top-K 会带来任务敏感权衡。
- 多物体、复杂场景、非图像领域和更广架构仍需研究。