

1

研究问题

RAE 的实用缺口

- 表征自编码器有望统一理解与生成 token，但重建质量仍落后于专用 VAE。
- 原始 RAE 不适配标准 CFG，需要额外训练一个较弱模型做 AutoGuidance。
- 以往只取编码器最后一层作为表征，忽略了不同深度中分布的信息。

4

自引导

REPA 头就是 X 预测器

- 在 RAE 潜空间中，REPA 投影头本就在从中间特征预测干净表征 x 。
- 把 DiT 输出重参数化为 x -prediction，即可把早期 REPA 头当作较弱的内部引导基线。
- 无需第二个模型，也无需 CFG 无条件前向；相对 CFG 可将函数评估次数减半。

2

广义 RAE

聚合最后 K 层

- 将冻结编码器输出定义为最后 K 层特征之和；K=1 即原始 RAE。
- 潜变量尺寸不变，无需微调编码器，也不需要专用文本或人脸数据。
- K 增大时重建持续改善；DINOv3-L 在 K=23 达 rFID 0.18、PSNR 27.03。

5

实验结果

收敛速度提升 10 倍

- RAEv2 在 ImageNet-256 上 80 epoch 即达 gFID 1.06，报告硬件上训练约 10.5 小时。
- 无需后训练，FDr6 从此前 800 epoch 的 3.26 改善为 80 epoch 的 2.17。
- EPFID@2 从 RAE 的 177 epoch 降至 35，并迁移到文生图与导航世界模型。

3

RAE + REPA

全局语义遇到空间结构

- 对 27 个编码器分析发现：RAE 主要利用全局语义，REPA 则改善中间特征的空间结构。
- 同一表征既作编码潜变量又作中间对齐目标，不会浪费容量，反而互补。
- 因此 DINOv3-L 等兼具全局与空间能力的强编码器能获得最佳生成表现。

6

研究意义

用效率衡量实际价值

- 冻结视觉编码器的低层细节分散在多层，而不只存在于顶层高语义特征。
- 微小 gFID 提升可能掩盖巨大训练代价，因此论文倡议报告达到目标质量所需 epoch。
- RAEv2 是精简训练配方而非更重架构，便于实际采用与继续扩展。

RAEV2 改进基线

Improved Baselines with Representation Autoencoders

表征自编码器改进基线

更快收敛、更好重建与零额外前向引导 | 2026

三条简单洞见释放 RAE 潜力：聚合冻结编码器多层特征、联合互补的 REPA 对齐，并复用 REPA 头实现无需额外前向的内部引导。

RAE

REPA

扩散 Transformer