

1 两类瓶颈

草稿质量与系统浪费

- 自回归起草器善于建模依赖，但延迟随候选长度线性增长。
- 并行起草器一次生成块，却因位置独立产生多模态冲突，后缀接受率快速衰减。
- 固定长度验证在高并发下把宝贵目标模型批容量浪费在高拒绝风险的后缀上。

2 半自回归

并行核心、串行纠偏

- DFlash 风格并行骨干用一次重前向生成全部隐藏状态与基础 logits。
- 轻量串行头加入依赖已采样前缀的转移偏置，同时保留精确逐词 softmax 概率。
- Markov 与 RNN 版本分别注入一步或完整块历史；默认低秩 Markov 头秩为 256。

3 置信度

预测前缀能否存活

- 小型置信头根据骨干状态和前一 token 嵌入，预测位置 k 的条件接受概率 c_k 。
- $c*_k = 1 - 0.5 ||p_{d,k} - p_{t,k}||_1$; $a_{r,j} = \text{product}_{(i \leq j)} c_{r,i}$
- 序列温度缩放校准累计存活概率，把平均 ECE 从 3–8% 降到约 1%。

DSPARK 推测解码

DSpark
置信度调度的半自回归推测解码

Confidence-Scheduled Speculative Decoding | 2026

用强并行骨干一次起草长块，用极轻量串行头恢复块内依赖，再根据校准后的前缀存活概率与实时系统成本决定目标模型验证预算。

推测解码

半自回归

高并发服务

4 硬件感知调度

最大化实时吞吐

- 引擎初始化时一次性测量验证批大小对应的 steps/s 曲线。
- 把所有请求的前缀扩展按存活概率全局排序，只在预期吞吐继续上升时接纳。
- 提前停止保证非前视性和目标分布精确；生产中的异步调度还能隐藏决策延迟。

5 实验结果

草稿更优、前沿外移

- Qwen3 4B/8B/14B 上，接受长度较 Eagle3 提升 30.9/26.7/30.0%，较 DFlash 提升 16.3/18.4/18.3%。
- 串行头只增加 0.2–1.3% 单轮延迟，却最多带来 30% 接受长度提升。
- DeepSeek-V4 真实流量中，同等实用吞吐下 Flash 单用户速度提升 60–85%，Pro 提升 57–78%。

6 局限与开放

验证更聪明，起草仍有成本

- 低负载时调度器扩展验证，高负载且目标容量饱和时主动剪短。
- 并行骨干仍需固定成本生成完整草稿块；本质低接受率的难请求可能无法回收成本。
- 未来可做难度感知提前退出；论文同时开放 DSpark 权重与 DeepSpec 训练仓库。