

2-2203.11171v4-Reasoning-Self Consistency

1 符号与维度

符号	维度	含义
x, z, a	--	问题、推理链与最终答案。
M	$\mathbb{N}$	独立采样推理链数量。
p	$[0, 1]$	单条链得到正确答案的概率。
ρ	$[-1, 1]$	不同采样正确性之间的相关系数。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 多数表决的精确错误概率

设每条独立推理路径给出正确最终答案的概率为 $p > 1/2$ ，采样奇数 $N = 2m + 1$ 条。正确票数

$$K \sim \text{Binomial}(N, p). \quad (2.1)$$

多数表决错误当且仅当 $K \leq m$ ，所以

$$P_{\text{err}}(N, p) = \sum_{k=0}^m \binom{N}{k} p^k (1-p)^{N-k}. \quad (2.2)$$

该式说明收益取决于路径正确率超过 $1/2$ ；若 $p < 1/2$ ，更多样本会更稳定地投向错误答案。

比较 N 与 $N + 2$ 可得错误概率递减。令 $N = 2m + 1$ ，枚举新增两票只在原表决接近边界时改变结果，可化为

$$P_{\text{err}}(N, p) - P_{\text{err}}(N + 2, p) = \binom{2m+1}{m} p^{m+1} (1-p)^{m+1} (2p-1) > 0. \quad (2.3)$$

3 Hoeffding 与 Chernoff 界

令 $X_i \in \{0, 1\}$ 表示第 i 条路径是否正确， $\bar{X} = N^{-1} \sum_i X_i$ 。Hoeffding 不等式给出

$$\mathbb{P}(\bar{X} \leq 1/2) = \mathbb{P}(\bar{X} - p \leq -(p - 1/2)) \quad (3.1)$$

$$\leq \exp[-2N(p - 1/2)^2]. \quad (3.2)$$

更紧的二项 Chernoff 界为

$$\mathbb{P}(\bar{X} \leq 1/2) \leq \exp[-ND_{\text{KL}}(1/2\|p)], \quad (3.3)$$

其中

$$D_{\text{KL}}(1/2\|p) = \frac{1}{2} \log \frac{1/2}{p} + \frac{1}{2} \log \frac{1/2}{1-p} = -\frac{1}{2} \log(4p(1-p)). \quad (3.4)$$

于是界也可写成 $[4p(1-p)]^{N/2}$ 。

若希望错误率不超过 δ ，Hoeffding 给出充分样本数

$$N \geq \frac{\log(1/\delta)}{2(p - 1/2)^2}. \quad (3.5)$$

当 p 只略高于 $1/2$ 时，所需样本数按优势平方的倒数增长。

4 路径相关性与有效样本量

语言模型样本共享同一提示和参数，正确指示变量通常相关。假设

$$\text{Var}(X_i) = \sigma^2 = p(1-p), \quad \text{Corr}(X_i, X_j) = \rho \quad (i \neq j). \quad (4.1)$$

则样本均值方差

$$\text{Var}(\bar{X}) = \frac{1}{N^2} [N\sigma^2 + N(N-1)\rho\sigma^2] \quad (4.2)$$

$$= \frac{\sigma^2}{N} [1 + (N-1)\rho]. \quad (4.3)$$

定义等方差有效样本量

$$N_{\text{eff}} = \frac{N}{1 + (N-1)\rho}. \quad (4.4)$$

若 $\rho > 0$ 固定， $N \rightarrow \infty$ 时 $N_{\text{eff}} \rightarrow 1/\rho$ ，收益饱和。因此提高温度或改变提示的作用不是“随机性越大越好”，而是尝试降低错误相关，同时不能让单路径 p 降得过多。

5 多类别答案的表决

正确答案概率为 p_* ，最大错误答案概率为 $p_2 = \max_{a \neq *} p_a$ 。plurality 表决失败意味着某个错误答案计数不低于正确答案。对固定错误答案 a ，定义

$$Y_i = \mathbf{1}\{A_i = *\} - \mathbf{1}\{A_i = a\} \in [-1, 1], \quad \mathbb{E}Y_i = p_* - p_a = \Delta_a. \quad (5.1)$$

事件 $N_a \geq N_*$ 等价于 $\sum_i Y_i \leq 0$ 。Hoeffding 给出

$$\mathbb{P}(N_a \geq N_*) \leq \exp\left(-\frac{N\Delta_a^2}{2}\right). \quad (5.2)$$

对 $M-1$ 个错误类别合并：

$$P_{\text{err}} \leq \sum_{a \neq *} \exp\left(-\frac{N(p_* - p_a)^2}{2}\right) \leq (M-1)e^{-N(p_* - p_2)^2/2}. \quad (5.3)$$

关键量是正确答案与最强错误答案的概率间隔，而不是正确率是否超过 $1/2$ 。

6 答案规范化是一个商空间映射

原始输出字符串空间记为 $\mathcal{Y}$ ，规范化函数 $g: \mathcal{Y} \rightarrow \mathcal{A}$ 把等价表达映射到同一答案。例如约分、去单位或数值格式统一。表决计数

$$C(a) = \sum_{i=1}^N \mathbf{1}\{g(y_i) = a\}, \quad \hat{a} = \arg \max_a C(a). \quad (6.1)$$

若两个语义相同答案未合并，其概率质量会被拆开： $p(a) = \sum_{y: g(y)=a} p(y)$ 没有在计数中实现，可能让单一错误格式获胜。

另一方面，过强规范化把不同答案错误合并。设真实等价关系为 $\sim$ ，安全的 g 应满足

$$y_1 \sim y_2 \Rightarrow g(y_1) = g(y_2), \quad (6.2)$$

同时尽量满足逆命题。前者不足造成拆票，后者不足造成误合并。

7 停止规则与计算预算

顺序采样时可在某答案票数领先幅度足够大时提前停止。若已采 n 条，领先者票数 c_1 、次名 c_2 ，剩余预算 $R = N_{\max} - n$ 。若

$$c_1 > c_2 + R, \quad (7.1)$$

则即使剩余全部投给次名，胜者也不会改变，这是确定性安全停止。

概率停止可对各答案概率设置后验。例如二元情形取 $p \sim \text{Beta}(\alpha_0, \beta_0)$ ，观察 k 次正确代理票后

$$p \mid k, n \sim \text{Beta}(\alpha_0 + k, \beta_0 + n - k). \quad (7.2)$$

当 $\mathbb{P}(p > 1/2 \mid k, n)$ 超过阈值时停止，可节省容易问题的采样量；但这里“正确票”在测试时不可直接观测，只能以当前领先类别构造近似，需注意选择偏差。

8 条件期望作为 L^2 正交投影

令随机向量 $Y \in L^2$ ，观测 Z 生成子空间

$$\mathcal{H}_Z = \{f(Z) : \mathbb{E}\|f(Z)\|^2 < \infty\}. \quad (8.1)$$

条件期望 $m(Z) = \mathbb{E}[Y \mid Z]$ 满足任意 $h(Z) \in \mathcal{H}_Z$ ：

$$\mathbb{E}[(Y - m(Z))^T h(Z)] = 0. \quad (8.2)$$

因为

$$\mathbb{E}[(Y - m)^T h] = \mathbb{E}\{\mathbb{E}[(Y - m)^T h \mid Z]\} \quad (8.3)$$

$$= \mathbb{E}\{h^T \mathbb{E}[Y - m \mid Z]\} = 0. \quad (8.4)$$

于是 Pythagoras 恒等式

$$\mathbb{E}\|Y - f(Z)\|^2 = \mathbb{E}\|Y - m(Z)\|^2 + \mathbb{E}\|m(Z) - f(Z)\|^2. \quad (8.5)$$

多数回归、去噪、流匹配和局部目标的“最优预测器”都由这一投影结论得到。

全方差公式也是同一正交分解：

$$\text{Var}(Y) = \mathbb{E} \text{Var}(Y \mid Z) + \text{Var}(\mathbb{E}[Y \mid Z]). \quad (8.6)$$

第一项是观测 Z 后仍不可约的不确定性，第二项是不同 Z 条件均值的变化。

9 Jensen、对数和与变分界

对凹函数 $\log$,

$$\log \mathbb{E}X \geq \mathbb{E} \log X, \quad X > 0. \quad (9.1)$$

差距可以写成 KL。令未归一权重 $w(z) > 0$ 、提议分布 $q(z)$ ，配分函数 $Z = \mathbb{E}_q w(z)$ ，定义

$$p^*(z) = \frac{q(z)w(z)}{Z}. \quad (9.2)$$

则

$$\log Z - \mathbb{E}_q \log w = \mathbb{E}_q \log \frac{Z}{w(z)} \quad (9.3)$$

$$= \mathbb{E}_q \log \frac{q(z)}{p^*(z)} \quad (9.4)$$

$$= D_{\text{KL}}(q \parallel p^*) \geq 0. \quad (9.5)$$

因此 Jensen 下界何时紧不只取决于“方差小”，而是提议分布是否等于归一化后的目标分布。

log-sum-exp

$$\text{LSE}(x) = \log \sum_{i=1}^n e^{x_i} \quad (9.6)$$

满足

$$\max_i x_i \leq \text{LSE}(x) \leq \max_i x_i + \log n. \quad (9.7)$$

减去最大值 $m = \max_i x_i$ 后计算

$$\text{LSE}(x) = m + \log \sum_i e^{x_i - m} \quad (9.8)$$

可避免指数上溢且数学等价。

10 Hoeffding 不等式的矩母函数推导

设独立 $X_i \in [a_i, b_i]$, $S = \sum_i (X_i - \mathbb{E}X_i)$ 。对任意 $\lambda > 0$, Markov 不等式

$$\mathbb{P}(S \geq t) = \mathbb{P}(e^{\lambda S} \geq e^{\lambda t}) \leq e^{-\lambda t} \mathbb{E}e^{\lambda S}. \quad (10.1)$$

独立性给出矩母函数乘积。Hoeffding 引理

$$\mathbb{E}e^{\lambda(X_i - \mathbb{E}X_i)} \leq \exp\left(\frac{\lambda^2(b_i - a_i)^2}{8}\right). \quad (10.2)$$

故

$$\mathbb{P}(S \geq t) \leq \exp\left(-\lambda t + \frac{\lambda^2}{8} \sum_i (b_i - a_i)^2\right). \quad (10.3)$$

对 λ 最小化,

$$\lambda^* = \frac{4t}{\sum_i (b_i - a_i)^2}, \quad (10.4)$$

得到

$$\mathbb{P}(S \geq t) \leq \exp\left(-\frac{2t^2}{\sum_i (b_i - a_i)^2}\right). \quad (10.5)$$

对下尾应用于 $-S$, 再 union bound 得双侧界。

11 Bernstein 界利用方差信息

若独立零均值 X_i 满足 $|X_i| \leq M$, 总方差 $v = \sum_i \mathbb{E}X_i^2$, Bernstein 界

$$\mathbb{P}\left(\sum_i X_i \geq t\right) \leq \exp\left(-\frac{t^2}{2(v + Mt/3)}\right). \quad (11.1)$$

当 $t \ll v/M$ 时近似高斯尾 $e^{-t^2/(2v)}$; 当 t 很大时转为 $e^{-3t/(2M)}$ 。相比只使用取值区间的 Hoeffding, 方差远小于最坏范围时 Bernstein 更紧。

对 Bernoulli 均值 $\hat{p} = N^{-1} \sum_i X_i$, $v = Np(1-p)$,

$$\mathbb{P}(|\hat{p} - p| \geq \epsilon) \leq 2 \exp\left(-\frac{N\epsilon^2}{2[p(1-p) + \epsilon/3]}\right). \quad (11.2)$$

12 并合界与同时保证

事件 $E_1, \dots, E_M$ 不要求独立也有

$$\mathbb{P}\left(\bigcup_{j=1}^M E_j\right) \leq \sum_{j=1}^M \mathbb{P}(E_j). \quad (12.1)$$

若每个失败概率至多 δ/M ，则全部结论同时成立的概率至少 $1 - \delta$ 。将单点集中界扩展到有限候选集合通常产生 $\log M$ 项。例如

$$2Me^{-2N\epsilon^2} \leq \delta \quad (12.2)$$

等价于

$$\epsilon \geq \sqrt{\frac{\log(2M/\delta)}{2N}}. \quad (12.3)$$

若候选集合无限，需要覆盖数、VC 维或 Rademacher 复杂度，而不能直接把 $M = \infty$ 代入。

13 Delta 方法与非线性估计误差

设 $\sqrt{N}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, \Sigma)$ ，光滑函数 g 的一阶展开

$$g(\hat{\theta}) = g(\theta) + \nabla g(\theta)^T (\hat{\theta} - \theta) + o_p(N^{-1/2}). \quad (13.1)$$

于是

$$\sqrt{N}[g(\hat{\theta}) - g(\theta)] \Rightarrow \mathcal{N}(0, \nabla g^T \Sigma \nabla g). \quad (13.2)$$

例如 $g(p) = \log p$ ，方差近似

$$\text{Var}(\log \hat{p}) \approx \frac{\text{Var}(\hat{p})}{p^2}. \quad (13.3)$$

当 p 很小时误差被 $1/p^2$ 放大，解释了稀有事件对数概率和概率比估计的不稳定。

二阶展开还给非线性偏差

$$\mathbb{E}g(\hat{\theta}) - g(\theta) \approx \frac{1}{2} \text{tr}(H_g(\theta) \text{Cov}(\hat{\theta})). \quad (13.4)$$

FID、比率、倒数和归一化优势等即使基础估计无偏，非线性组合也可有有限样本偏差。

14 重要性采样与有效样本量

目标期望 $\mathbb{E}_p f(X)$ 用提议 q 采样，权重 $w(x) = p(x)/q(x)$ ：

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N w(X_i) f(X_i), \quad X_i \sim q. \quad (14.1)$$

若 p 的归一化常数未知，使用自归一估计

$$\tilde{\mu} = \frac{\sum_i w_i f_i}{\sum_i w_i}, \quad (14.2)$$

它一般有 $O(1/N)$ 偏差，但常更实用。权重退化可用

$$N_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2} \quad (14.3)$$

衡量；权重相等时为 N ，单个权重主导时接近 1。

比率裁剪 $\tilde{w} = \min(w, c)$ 降低方差，但引入偏差

$$\mathbb{E}_q[(w - \tilde{w})f] = \mathbb{E}_q[(w - c)_+ f]. \quad (14.4)$$

若 $|f| \leq F$ ，绝对偏差至多

$$F \mathbb{E}_q[(w - c)_+]. \quad (14.5)$$

15 校准与 Brier 分解

二元预测概率 $P \in [0, 1]$ 、标签 $Y \in \{0, 1\}$ 。条件真实频率 $m(P) = \mathbb{E}[Y \mid P]$ 。Brier 分数

$$\mathbb{E}(P - Y)^2 = \mathbb{E}(P - m(P))^2 + \mathbb{E}(m(P) - Y)^2, \quad (15.1)$$

交叉项因条件期望为零而消失。第一项是校准误差，第二项是给定预测分组后的不可约噪声。若模型完美校准， $m(P) = P$ ，第一项为零，但单次预测仍可错误；校准不是零错误率，而是概率与长期频率一致。