

4-2103.00020v1-Visual-CLIP

1 符号与维度

符号	维度	含义
u_i, v_i	$\mathbb{R}^d$	第 i 个图像与文本的单位化嵌入。
s_{ij}	$\mathbb{R}$	图像 i 与文本 j 的缩放余弦 logit。
τ	$\mathbb{R}_{>0}$	softmax 温度。
N	$\mathbb{N}$	对比学习批大小。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 对称图文对比目标

一批 N 对图像与文本，经编码和单位化得到 $u_i, v_j \in \mathbb{R}^d$ ， $\|u_i\| = \|v_j\| = 1$ 。logit

$$z_{ij} = \frac{u_i^T v_j}{\tau}. \quad (2.1)$$

图到文损失

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{N} \sum_i \log \frac{e^{z_{ii}}}{\sum_j e^{z_{ij}}}, \quad (2.2)$$

文到图损失对列作 softmax:

$$\mathcal{L}_{T \rightarrow I} = -\frac{1}{N} \sum_j \log \frac{e^{z_{jj}}}{\sum_i e^{z_{ij}}}. \quad (2.3)$$

总损失常取二者平均。对一行，记 $p_{ij} = e^{z_{ij}} / \sum_k e^{z_{ik}}$ ，则

$$\frac{\partial \mathcal{L}_{I \rightarrow T}}{\partial z_{ij}} = \frac{1}{N} (p_{ij} - \mathbf{1}\{i = j\}). \quad (2.4)$$

因此

$$\frac{\partial \mathcal{L}_{I \rightarrow T}}{\partial u_i} = \frac{1}{N\tau} \left(\sum_j p_{ij} v_j - v_i \right). \quad (2.5)$$

梯度把图像向量拉向正文本，并按当前混淆概率推离负文本；困难负样本权重更大。

3 单位化的 Jacobian

网络原始输出 $h \neq 0$ ，单位向量 $u = h / \|h\|_2$ 。令 $r = \|h\|$,

$$du = \frac{dh}{r} - \frac{h(h^T dh)}{r^3} = \frac{1}{r} (I - uu^T) dh. \quad (3.1)$$

故

$$\boxed{J_{u \leftarrow h} = \frac{1}{\|h\|} (I - uu^T).} \quad (3.2)$$

反向梯度

$$\nabla_h \mathcal{L} = \frac{1}{\|h\|} (I - uu^T) \nabla_u \mathcal{L} \quad (3.3)$$

与 u 正交，所以一阶更新只改变方向而不改变径向分量。若 $\|h\|$ 很小，梯度会放大，实际实现需用数值下界。

单位化后相似度是余弦， $-1 \leq u^T v \leq 1$ ，模型不能靠增大特征范数无限降低交叉熵；整体 logit 尺度交给温度参数。

4 温度的导数与熵效应

令 $s_{ij} = u_i^T v_j$ 、 $z_{ij} = s_{ij}/\tau$ 。单行损失

$$\ell_i = -\frac{s_{ii}}{\tau} + \log \sum_j e^{s_{ij}/\tau}. \quad (4.1)$$

对 τ 求导：

$$\frac{\partial \ell_i}{\partial \tau} = \frac{1}{\tau^2} \left(s_{ii} - \sum_j p_{ij} s_{ij} \right). \quad (4.2)$$

若正相似度高于当前 softmax 平均，梯度下降会减小 τ ，使分布更尖锐。实践中常参数化 $\gamma = \log(1/\tau)$ ，此时

$$\frac{\partial \ell_i}{\partial \gamma} = \sum_j p_{ij} z_{ij} - z_{ii}. \quad (4.3)$$

对 γ 限幅可防止温度趋近零造成 logit 与梯度过大。

5 InfoNCE 互信息下界的条件

设正样本 $(X, Y_1) \sim p(x, y)$ ，其余 $Y_2, \dots, Y_N$ 独立来自边缘 $p(y)$ 。从 N 个候选中识别正样本索引 I 。最优分类后验正比密度比

$$\mathbb{P}(I = i \mid x, y_{1:N}) \propto \frac{p(y_i \mid x)}{p(y_i)}. \quad (5.1)$$

用得分 $f(x, y) > 0$ 近似该密度比，InfoNCE

$$\mathcal{L}_N = -\mathbb{E} \log \frac{f(X, Y_1)}{\sum_{j=1}^N f(X, Y_j)}. \quad (5.2)$$

标准推导给出

$$\boxed{I(X; Y) \geq \log N - \mathcal{L}_N}. \quad (5.3)$$

它要求负样本来自正确边缘分布并独立；批内语义重复、配对噪声或数据相关会改变该严格解释。此外下界至多为 $\log N$ ，大批量提高可表达的下界上限，但计算和假负样本概率也上升。

6 批内负样本梯度的统计耦合

每个样本既是自身正样本，又是其他 $N - 1$ 个样本的负样本。因此 v_j 的总梯度含

$$\nabla_{v_j} \mathcal{L}_{I \rightarrow T} = \frac{1}{N\tau} \left(\sum_i p_{ij} u_i - u_j \right). \quad (6.1)$$

若两个不同索引实际语义相同，项 $p_{ij} u_i$ 仍把它当负样本推开，这就是假负样本偏差。增大批量降低 softmax 分母的抽样噪声，却可能增加语义碰撞，二者需同时考虑。

若使用跨设备 all-gather，只有本设备特征保留梯度而远端特征停止梯度，则前向负样本集合相同，但远端样本不接收作为 negative 的反向贡献；这与全局可微 gather 的优化目标并不完全相同。

7 动量编码器与软目标

动量参数递推

$$\bar{\theta}_k = m\bar{\theta}_{k-1} + (1-m)\theta_k \quad (7.1)$$

展开为

$$\bar{\theta}_k = m^k \bar{\theta}_0 + (1-m) \sum_{j=1}^k m^{k-j} \theta_j. \quad (7.2)$$

因此教师是历史学生的指数平均，有效窗口约为 $1/(1-m)$ 。

若硬标签 e_i 与动量教师分布 q_i 混合

$$y_i = (1-\alpha)e_i + \alpha q_i, \quad (7.3)$$

交叉熵对学生 logit 的梯度为

$$\nabla_z \ell = p_i - y_i = (1-\alpha)(p_i - e_i) + \alpha(p_i - q_i). \quad (7.4)$$

所以软蒸馏项把教师对其他样本的相似性结构传给学生，同时可能传播教师偏差。

8 图文匹配与对比学习的差别

双塔对比模型的得分是独立编码后的内积，所有图文表征可预计算；跨模态融合模型让 token 之间交互，匹配 logit $a_\theta(I, T)$ 的二元损失为

$$\ell_{\text{ITM}} = -y \log \sigma(a) - (1-y) \log(1 - \sigma(a)), \quad \frac{\partial \ell}{\partial a} = \sigma(a) - y. \quad (8.1)$$

它能表达细粒度对应，但每一候选对都需联合前向。实践中先用对比相似度检索困难负样本，再用融合编码器判别，是计算量与交互能力之间的分解。

9 自回归似然与 token 梯度

对序列 $x_{1:T}$ ，因果语言模型按概率链式法则分解

$$p_\theta(x_{1:T}) = \prod_{t=1}^T p_\theta(x_t | x_{<t}). \quad (9.1)$$

负对数似然

$$\mathcal{L}_{\text{NLL}} = - \sum_{t=1}^T \log p_\theta(x_t | x_{<t}). \quad (9.2)$$

若第 t 步 logits 为 $z_t \in \mathbb{R}^V$ ，概率 $p_{tj} = e^{z_{tj}} / \sum_k e^{z_{tk}}$ ，真实 token 索引 y_t ，则

$$\ell_t = -z_{t,y_t} + \log \sum_k e^{z_{tk}}, \quad (9.3)$$

逐 logit 梯度

$$\frac{\partial \ell_t}{\partial z_{tj}} = p_{tj} - \mathbf{1}\{j = y_t\}. \quad (9.4)$$

Hessian 正是 softmax Jacobian

$$\nabla_z^2 \ell_t = \text{diag}(p_t) - p_t p_t^T \succeq 0. \quad (9.5)$$

所以交叉熵关于 logits 凸，但关于深网参数并不凸。

对非 padding token 集合 $\mathcal{I}$, 平均损失和困惑度

$$\bar{L} = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \ell_t, \quad \text{PPL} = e^{\bar{L}}. \quad (9.6)$$

因此 PPL 是真实 token 概率倒数的几何平均:

$$\text{PPL} = \left(\prod_{t \in \mathcal{I}} \frac{1}{p_\theta(x_t | x_{<t})} \right)^{1/|\mathcal{I}|}. \quad (9.7)$$

不同 tokenizer 的 token 粒度不同, PPL 不能不经换算直接横向比较。

10 旋转位置编码的相对位置恒等式

对二维坐标对, 定义旋转

$$R(m\omega) = \begin{bmatrix} \cos(m\omega) & -\sin(m\omega) \\ \sin(m\omega) & \cos(m\omega) \end{bmatrix}. \quad (10.1)$$

位置 m, n 的 query、key 分别为 $q_m = R(m\omega)q$ 、 $k_n = R(n\omega)k$ 。内积

$$q_m^T k_n = q^T R(m\omega)^T R(n\omega) k \quad (10.2)$$

$$= q^T R((n-m)\omega) k. \quad (10.3)$$

第二步用到 $R(a)^T = R(-a)$ 和 $R(a)R(b) = R(a+b)$ 。所以绝对位置旋转后的内积只依赖相对距离 $n-m$ 。

在 d_h 维中对相邻坐标对使用频率

$$\omega_j = \theta^{-2j/d_h}, \quad j = 0, \dots, d_h/2 - 1. \quad (10.4)$$

低 j 频率高、分辨近距离, 高 j 频率低、覆盖远距离。若推理长度远超训练长度, 相位 $m\omega_j$ 的外推和周期混叠会改变注意力几何; 位置插值本质上是重新缩放这些相位。

11 RMSNorm 的 Jacobian

忽略可学习增益, RMSNorm

$$y = \frac{x}{s}, \quad s = \sqrt{\frac{1}{d} x^T x + \epsilon}. \quad (11.1)$$

微分

$$ds = \frac{x^T dx}{ds}, \quad (11.2)$$

因此

$$dy = \frac{1}{s} dx - \frac{x}{s^2} ds \quad (11.3)$$

$$= \left(\frac{1}{s} I - \frac{xx^T}{ds^3} \right) dx. \quad (11.4)$$

故

$$J_{\text{RMS}} = \frac{1}{s} I - \frac{xx^T}{ds^3}. \quad (11.5)$$

与 LayerNorm 相比, 它没有去均值投影 $I - d^{-1}\mathbf{1}\mathbf{1}^T$, 因此不消除常数方向。加上逐坐标增益 g 后, Jacobian 左乘 $\text{diag}(g)$ 。

谱上, 对任意 $v \perp x$, $Jv = v/s$; 沿 x 方向

$$Jx = \left(\frac{1}{s} - \frac{\|x\|^2}{ds^3} \right) x = \frac{\epsilon}{s^3} x. \quad (11.6)$$

当 ϵ 很小, 径向尺度方向被强烈压制, 而切向方向按 $1/s$ 缩放。

12 SwiGLU 前馈层的逐项梯度

SwiGLU 可写

$$a = xW_a, \quad b = xW_b, \quad h = \text{swish}(a) \odot b, \quad y = hW_o, \quad (12.1)$$

其中

$$\text{swish}(a) = a\sigma(a). \quad (12.2)$$

其导数

$$\frac{d}{da}[a\sigma(a)] = \sigma(a) + a\sigma(a)(1 - \sigma(a)). \quad (12.3)$$

令 $g_h = \partial\mathcal{L}/\partial h$, 则

$$g_a = g_h \odot b \odot [\sigma(a) + a\sigma(a)(1 - \sigma(a))], \quad (12.4)$$

$$g_b = g_h \odot \text{swish}(a), \quad (12.5)$$

$$\nabla_{W_a}\mathcal{L} = x^T g_a, \quad \nabla_{W_b}\mathcal{L} = x^T g_b, \quad (12.6)$$

$$\nabla_x\mathcal{L} = g_a W_a^T + g_b W_b^T. \quad (12.7)$$

门分支 b 同时调制激活和 a 分支梯度, 故两个投影不是可独立解释的普通 MLP。

13 MoE 路由与负载

对 token x_i , router logits $r_i = W_r x_i$, 概率

$$p_{ie} = \frac{e^{r_{ie}}}{\sum_{j=1}^E e^{r_{ij}}}. \quad (13.1)$$

若 top- k 专家集合 S_i , 归一化门

$$\tilde{p}_{ie} = \frac{p_{ie} \mathbf{1}\{e \in S_i\}}{\sum_{j \in S_i} p_{ij}}, \quad y_i = \sum_{e \in S_i} \tilde{p}_{ie} F_e(x_i). \quad (13.2)$$

固定集合 S_i 内可正常求导; 集合边界的 arg-top- k 不连续, 几乎处处把未选专家梯度置零。

令软重要性

$$P_e = \frac{1}{N} \sum_i p_{ie}, \quad (13.3)$$

硬负载

$$F_e = \frac{1}{N} \sum_i \mathbf{1}\{e \in S_i\}/k. \quad (13.4)$$

常见平衡项

$$L_{\text{bal}} = E \sum_e P_e F_e \quad (13.5)$$

在均匀 $P_e = F_e = 1/E$ 时等于 1。把硬 F_e 停止梯度后, router 梯度只通过 P_e , 会降低当前过载专家的概率; 它是训练启发式, 不等同于严格容量约束。

若每专家容量为

$$C_e = \left\lceil \frac{Nk}{E} c_{\text{cap}} \right\rceil, \quad (13.6)$$

超过容量的 token 必须丢弃或转送。即使平均负载均匀, 局部批次方差仍可能溢出。

14 低秩 KV 潜变量的吸收

设 key/value 由共享潜变量

$$c_t = W_c x_t \in \mathbb{R}^{d_c}, \quad k_t = W_k c_t, \quad v_t = W_v c_t. \quad (14.1)$$

注意力 logit

$$q_s^T k_t = q_s^T W_k c_t = (W_k^T q_s)^T c_t. \quad (14.2)$$

因此解码时可把 W_k 吸收到 query 投影，缓存 c_t 而非完整 k_t 。若 value 聚合

$$o_s = \sum_t p_{st} W_v c_t = W_v \left(\sum_t p_{st} c_t \right), \quad (14.3)$$

W_v 可放到加权和之后。缓存从每 token 的 $d_k + d_v$ 降为 d_c ，前提是位置编码等操作不破坏这些线性交换关系；对只作用在部分 key 维度的 RoPE，需把旋转部分另行缓存或重构。

15 多 token 预测的联合似然

若同一隐藏状态 h_t 用 K 个头预测 $x_{t+1}, \dots, x_{t+K}$,

$$\mathcal{L}_t = \sum_{k=1}^K \lambda_k [-\log p_{\theta,k}(x_{t+k} | h_t)]. \quad (15.1)$$

共享骨干梯度

$$\nabla_{h_t} \mathcal{L}_t = \sum_{k=1}^K \lambda_k g_{t,k}. \quad (15.2)$$

其平方范数精确展开

$$\left\| \sum_k \lambda_k g_{t,k} \right\|^2 = \sum_k \lambda_k^2 \|g_{t,k}\|^2 + 2 \sum_{j < k} \lambda_j \lambda_k g_{t,j}^T g_{t,k}. \quad (15.3)$$

交叉内积为负时存在任务冲突；辅助头退火相当于训练后期逐渐去掉这些交叉项，使最终目标回到下一 token 似然。