

5-1312.05602v1-Reinforcement-DQN

1 符号与维度

符号	维度	含义
s, a, r, s'	--	状态、动作、奖励与下一状态。
Q_θ, Q_{θ^-}	$\mathbb{R}$	在线与目标动作价值网络。
γ	$[0, 1)$	折扣因子。
d	$\{0, 1\}$	终止标记。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 Bellman 最优算子的压缩映射证明

对有界动作价值函数 Q ，定义

$$(T^*Q)(s, a) = r(s, a) + \gamma \mathbb{E}_{s'|s, a} \max_{a'} Q(s', a'). \quad (2.1)$$

取任意 Q_1, Q_2 。利用

$$|\max_i x_i - \max_i y_i| \leq \max_i |x_i - y_i|, \quad (2.2)$$

逐状态动作有

$$|(T^*Q_1 - T^*Q_2)(s, a)| \leq \gamma \mathbb{E}_{s'} \left| \max_{a'} Q_1(s', a') - \max_{a'} Q_2(s', a') \right| \quad (2.3)$$

$$\leq \gamma \|Q_1 - Q_2\|_\infty. \quad (2.4)$$

取上确界得到

$$\|T^*Q_1 - T^*Q_2\|_\infty \leq \gamma \|Q_1 - Q_2\|_\infty. \quad (2.5)$$

因 $0 \leq \gamma < 1$ ，Banach 不动点定理保证唯一 Q^* 且精确值迭代收敛。神经网络 DQN 并非精确表格迭代，函数逼近、离策略采样和移动目标会破坏这一直接保证。

3 TD 平方损失与半梯度

固定目标网络参数 $\bar{\theta}$ ，单样本目标

$$y = r + \gamma(1 - d) \max_{a'} Q_{\bar{\theta}}(s', a') \quad (3.1)$$

以及损失

$$\ell(\theta) = \frac{1}{2}(y - Q_\theta(s, a))^2. \quad (3.2)$$

因 y 对在线参数停止梯度，

$$\nabla_\theta \ell = -(y - Q_\theta(s, a)) \nabla_\theta Q_\theta(s, a). \quad (3.3)$$

这称为半梯度。若目标也用同一 θ 且不停止梯度，则

$$\nabla_\theta \ell = (Q_\theta - y_\theta) (\nabla Q_\theta(s, a) - \gamma \nabla Q_\theta(s', a^*)), \quad (3.4)$$

其中 $a^* = \arg \max_{a'} Q_\theta(s', a')$ 在唯一最大值处局部常数。这不是通常 DQN 的更新，并会让目标与预测同时移动。

设 Bellman 误差 $\delta = y - Q_\theta(s, a)$ 。一次梯度下降后，对小步长 η ,

$$Q_{\theta^+}(s, a) \approx Q_\theta(s, a) + \nabla Q_\theta(s, a)^T (\theta^+ - \theta) \quad (3.5)$$

$$= Q_\theta(s, a) + \eta \delta \|\nabla Q_\theta(s, a)\|_2^2. \quad (3.6)$$

所以 $\delta > 0$ 时该动作价值局部上升，步幅还受网络 Jacobian 范数调制。

4 目标网络作为时间尺度分离

硬更新每 C 步令 $\bar{\theta} \leftarrow \theta$ 。软更新为

$$\bar{\theta}_{k+1} = (1 - \tau)\bar{\theta}_k + \tau\theta_k. \quad (4.1)$$

递归展开

$$\bar{\theta}_k = (1 - \tau)^k \bar{\theta}_0 + \tau \sum_{j=0}^{k-1} (1 - \tau)^{k-1-j} \theta_j. \quad (4.2)$$

因此目标网络是在线参数的指数移动平均，有效记忆长度约为 $1/\tau$ 。它减少目标抖动，但过小 τ 会增加滞后偏差。

5 经验回放改变的采样分布

在线相邻转移通常相关；回放缓冲区中均匀抽样近似经验分布

$$\hat{\mu}(s, a, r, s') = \frac{1}{N} \sum_{i=1}^N \delta_{(s_i, a_i, r_i, s'_i)}. \quad (5.1)$$

小批梯度

$$\hat{g} = \frac{1}{B} \sum_{i \in \mathcal{B}} \nabla \ell_i \quad (5.2)$$

在相对缓冲经验分布下无偏，但一般不相对当前策略占用分布无偏。Q-learning 的 Bellman 最优目标允许离策略数据，前提仍需足够覆盖相关状态动作。

优先回放令采样概率

$$P(i) = \frac{p_i^\alpha}{\sum_j p_j^\alpha}, \quad (5.3)$$

为校正到均匀经验目标，重要性权重可取

$$w_i = \left(\frac{1}{NP(i)} \right)^\beta. \quad (5.4)$$

$\beta = 1$ 完全校正， $\beta < 1$ 在偏差与方差之间折衷。归一化 $w_i / \max_j w_j$ 进一步改变整体梯度尺度，但不改变方向的相对加权。

6 最大值造成的过估计偏差

设估计 $\hat{Q}_a = Q_a + \epsilon_a$ 且 $\mathbb{E}\epsilon_a = 0$ 。由最大值是凸函数，Jensen 不等式给出

$$\mathbb{E} \max_a \hat{Q}_a \geq \max_a \mathbb{E} \hat{Q}_a = \max_a Q_a. \quad (6.1)$$

Double DQN 用在线网络选动作、目标网络估值：

$$a^* = \arg \max_a Q_\theta(s', a), \quad y = r + \gamma Q_{\bar{\theta}}(s', a^*). \quad (6.2)$$

当两网络误差不完全相关时，选择噪声与评估噪声被部分解耦，从而降低而非必然消除过估计。

7 n 步目标的偏差与传播

n 步目标为

$$y_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k r_{t+k} + \gamma^n \max_a Q_{\bar{\theta}}(s_{t+n}, a). \quad (7.1)$$

若 bootstrap 估计误差为 e_{t+n} ，它进入目标的幅度为 $\gamma^n e_{t+n}$ ；增大 n 会指数削弱 bootstrap 偏差，却累积更多随机奖励方差。令奖励独立、方差 σ_r^2 ，仅奖励和的方差为

$$\text{Var} \left(\sum_{k=0}^{n-1} \gamma^k r_{t+k} \right) = \sigma_r^2 \sum_{k=0}^{n-1} \gamma^{2k} = \sigma_r^2 \frac{1 - \gamma^{2n}}{1 - \gamma^2}. \quad (7.2)$$

这给出 n 步回报经典的偏差-方差权衡。

8 Bellman 期望方程与优势恒等式

对策略 π ，定义

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s \right], \quad (8.1)$$

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a \right]. \quad (8.2)$$

分离首步奖励：

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s'), \quad (8.3)$$

$$V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot|s)} Q^\pi(s, a). \quad (8.4)$$

优势

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (8.5)$$

在策略动作分布下均值为零：

$$\mathbb{E}_{a \sim \pi} A^\pi(s, a) = 0. \quad (8.6)$$

这不表示每个动作优势小，只表示正负改进机会按当前策略加权抵消。

9 性能差异引理

令新旧策略为 π', π 。沿 π' 轨迹，

$$\mathbb{E}_{\pi'} \sum_{t=0}^{\infty} \gamma^t A^\pi(s_t, a_t) = \mathbb{E}_{\pi'} \sum_t \gamma^t [r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t)] \quad (9.1)$$

$$= J(\pi') - \mathbb{E} V^\pi(s_0), \quad (9.2)$$

其中价值项望远镜消去，且有界价值使末项 $\gamma^{T+1} V(s_{T+1}) \rightarrow 0$ 。若初始分布相同， $\mathbb{E} V^\pi(s_0) = J(\pi)$ ，故

$$\boxed{J(\pi') - J(\pi) = \frac{1}{1 - \gamma} \mathbb{E}_{s \sim d_{\pi'}, a \sim \pi'} A^\pi(s, a).} \quad (9.3)$$

策略优化代理常把难采样的 $d_{\pi'}$ 替换为旧占用分布 d_π ；信赖域或比率裁剪的目标是限制这一步替换造成的误差。

10 KL 信赖域的二阶局部形式

对小参数变化 $\Delta\theta$,

$$D_{\text{KL}}(\pi_\theta \| \pi_{\theta+\Delta}) = \frac{1}{2} \Delta^T F(\theta) \Delta + O(\|\Delta\|^3), \quad (10.1)$$

其中 Fisher 信息

$$F(\theta) = \mathbb{E}_{s,a} [\nabla \log \pi_\theta(a | s) \nabla \log \pi_\theta(a | s)^T]. \quad (10.2)$$

一阶目标改进 $g^T \Delta$, 约束 $\frac{1}{2} \Delta^T F \Delta \leq \delta$ 。拉格朗日法:

$$\mathcal{J} = g^T \Delta - \lambda \left(\frac{1}{2} \Delta^T F \Delta - \delta \right). \quad (10.3)$$

驻点

$$g - \lambda F \Delta = 0 \Rightarrow \Delta = \lambda^{-1} F^{-1} g. \quad (10.4)$$

代回约束得到

$$\Delta = \sqrt{\frac{2\delta}{g^T F^{-1} g}} F^{-1} g. \quad (10.5)$$

自然梯度 $F^{-1}g$ 是概率分布几何下最陡方向; PPO 裁剪是更易实现但不严格等价的近似。

11 离策略序列比率的方差

轨迹前 T 步重要性比率

$$W_T = \prod_{t=0}^{T-1} \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}. \quad (11.1)$$

在行为策略 μ 下若支撑相容, $\mathbb{E}_\mu W_T = 1$ 。对数比率是和

$$\log W_T = \sum_t \ell_t, \quad \ell_t = \log \pi(a_t | s_t) - \log \mu(a_t | s_t). \quad (11.2)$$

若粗略假设 ℓ_t 独立、均值 m 、方差 v , 则 W_T 近似 log-normal,

$$\frac{\text{Var}(W_T)}{(\mathbb{E}W_T)^2} \approx e^{Tv} - 1. \quad (11.3)$$

方差随长度指数增长, 这解释了 token/step 级截断、V-trace 或短视野校正的必要性。

截断 $\bar{w}_t = \min(c, w_t)$ 产生偏差, 但单步权重有界, 能控制乘积和梯度爆炸。偏差精确来自尾部

$$\mathbb{E}_\mu[(w_t - c)_+ f_t]. \quad (11.4)$$

12 熵正则的策略梯度

状态熵

$$\mathcal{H}(\pi_\theta) = - \sum_a \pi_\theta(a) \log \pi_\theta(a). \quad (12.1)$$

求导

$$\nabla \mathcal{H} = - \sum_a \nabla \pi(a) [1 + \log \pi(a)] \quad (12.2)$$

$$= -\mathbb{E}_{a \sim \pi} [(1 + \log \pi(a)) \nabla \log \pi(a)]. \quad (12.3)$$

因 $\mathbb{E} \nabla \log \pi = 0$, 常数 1 可去掉:

$$\nabla \mathcal{H} = -\mathbb{E}[\log \pi(a) \nabla \log \pi(a)]. \quad (12.4)$$

加入 $+\alpha \mathcal{H}$ 会提高低概率动作的相对激励, 防止策略过早坍缩; 但在可验证答案任务中, 过强熵也会降低正确答案集中度。

13 奖励平移、缩放与归一化

若所有奖励加常数 c ，无限折扣回报

$$G'_t = G_t + \frac{c}{1-\gamma}. \quad (13.1)$$

精确优势不变，因为 Q, V 同时加 $c/(1-\gamma)$ 。用采样回报而无正确基线时，常数会增加梯度方差但期望 score 项仍抵消。

奖励乘正数 a 时，优势和策略梯度乘 a ，等价于改变有效学习率；PPO 的裁剪边界不随 a 变，所以裁剪区域不变但目标梯度尺度变。组内标准化

$$\hat{A}_i = \frac{R_i - \bar{R}}{s_R + \epsilon} \quad (13.2)$$

同时消除平移并近似消除尺度，但 s_R 很小时会放大噪声，故需要 ϵ 或跳过全同奖励组。

14 KL 正则与奖励塑形

目标

$$J(\pi) = \mathbb{E}_\pi[R] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}) \quad (14.1)$$

可写为每步塑形奖励

$$r'_t = r_t - \beta [\log \pi(a_t | s_t) - \log \pi_{\text{ref}}(a_t | s_t)]. \quad (14.2)$$

固定状态、给定动作价值 $Q(a)$ 时，最优非参数策略由拉格朗日法得到

$$\pi^*(a) = \frac{\pi_{\text{ref}}(a) e^{Q(a)/\beta}}{\sum_b \pi_{\text{ref}}(b) e^{Q(b)/\beta}}. \quad (14.3)$$

$\beta \rightarrow 0$ 时集中到高价值动作， $\beta \rightarrow \infty$ 时回到参考策略。参考策略为零概率的动作在正向 KL 约束下永远不可选，故支撑选择很重要。

15 拒答动作与错误成本

设回答正确收益 u_c 、错误收益 u_e 、拒答收益 u_a ，模型置信度 $p = \mathbb{P}(\text{correct} | s)$ 。回答期望效用

$$U_{\text{ans}}(p) = pu_c + (1-p)u_e, \quad (15.1)$$

拒答效用 $U_{\text{abstain}} = u_a$ 。当

$$p \geq \frac{u_a - u_e}{u_c - u_e} \quad (15.2)$$

时回答更优（假设 $u_c > u_e$ ）。因此最优置信阈值由错误和拒答的相对成本决定，不是固定的 1/2。RL 后训练若隐含奖励给拒答过低分，就会系统性鼓励猜测。

16 有限 horizon 的回报界

若 $|r_t| \leq R_{\text{max}}$ ，无限折扣回报有界

$$|G_t| \leq \sum_{k=0}^{\infty} \gamma^k R_{\text{max}} = \frac{R_{\text{max}}}{1-\gamma}. \quad (16.1)$$

截断到 H 步的尾部误差

$$\left| G_t - \sum_{k=0}^{H-1} \gamma^k r_{t+k} \right| \leq \frac{\gamma^H R_{\text{max}}}{1-\gamma}. \quad (16.2)$$

要使其不超过 ϵ ，充分条件

$$H \geq \frac{\log[\epsilon(1-\gamma)/R_{\max}]}{\log \gamma}, \quad (16.3)$$

注意 $\log \gamma < 0$ ，除法会反转不等号，右端为正。