

5-1712.01815v1-Reinforcement-AlphaGo Zero

1 符号与维度

符号	维度	含义
P, Q, N	--	MCTS 先验、均值价值与访问计数。
π, p_θ	$\Delta^{ \mathcal{A} -1}$	搜索策略与网络策略。
v_θ, z	$[-1, 1]$	价值预测与最终胜负。
τ	$\mathbb{R}_{>0}$	访问计数温度。

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

2 PUCT 选择项的来源与尺度

树中边 (s, a) 维护访问次数 $N(s, a)$ 、价值和 $W(s, a)$ 、均值

$$Q(s, a) = \frac{W(s, a)}{N(s, a)} \quad (2.1)$$

以及网络先验 $P(s, a)$ 。PUCT 选择

$$a^* = \arg \max_a \{Q(s, a) + U(s, a)\}, \quad U(s, a) = c_{\text{puct}} P(s, a) \frac{\sqrt{\sum_b N(s, b)}}{1 + N(s, a)}. \quad (2.2)$$

当一条边未访问时分母为 1，先验大的动作更先被探索；固定父节点总访问数， U 随该边访问次数约按 $1/N(s, a)$ 衰减。若所有动作最终都被无限访问，探索项趋于零，选择逐渐由 Q 主导。

对访问次数作连续近似，若多个动作的有效上界在平衡时接近，

$$Q_a + cP_a \frac{\sqrt{N}}{1 + N_a} \approx C, \quad (2.3)$$

可解出

$$N_a \approx \frac{cP_a \sqrt{N}}{C - Q_a} - 1. \quad (2.4)$$

因此访问量同时依赖先验与价值差，不等价于只按策略概率采样。

3 叶子价值的反向备份

一次模拟到叶子得到当前玩家视角价值 $v \in [-1, 1]$ 。若玩家每层交替，沿路径反向备份

$$N(s_t, a_t) \leftarrow N(s_t, a_t) + 1, \quad W(s_t, a_t) \leftarrow W(s_t, a_t) + (-1)^{L-t} v. \quad (3.1)$$

符号翻转来自零和对弈中双方价值相反。更新后的均值

$$Q^+ = \frac{W + z}{N + 1} = Q + \frac{z - Q}{N + 1} \quad (3.2)$$

是在线样本均值递推。若叶子估计 z 条件无偏、方差 σ^2 ，独立访问下 Q 的方差按 σ^2/N 衰减。

4 访问次数形成改进策略

搜索后策略目标为

$$\pi(a | s) = \frac{N(s, a)^{1/\tau}}{\sum_b N(s, b)^{1/\tau}}. \quad (4.1)$$

$\tau \rightarrow 0$ 时集中到最大访问动作, $\tau = 1$ 时按访问频率, $\tau \rightarrow \infty$ 时趋于均匀。令 $z_a = \log N(s, a)$, 则

$$\pi(a | s) = \text{softmax}(z_a / \tau), \quad (4.2)$$

所以温度对分布熵的影响与普通 softmax 完全相同。

网络策略头 p_θ 拟合搜索策略的交叉熵

$$\mathcal{L}_p = - \sum_a \pi(a | s) \log p_\theta(a | s). \quad (4.3)$$

若 logits 为 l , 则

$$\frac{\partial \mathcal{L}_p}{\partial l_a} = p_\theta(a | s) - \pi(a | s). \quad (4.4)$$

因此搜索不是不可微模块的反向传播对象; 它产生一个经规划改进的监督分布。

5 价值、策略与正则的联合损失

单个自博弈样本 (s, π, z) 的联合目标

$$\mathcal{L}(\theta) = (z - v_\theta(s))^2 - \pi^T \log p_\theta(\cdot | s) + c \|\theta\|_2^2. \quad (5.1)$$

对应梯度为

$$\nabla \mathcal{L} = 2(v_\theta - z) \nabla v_\theta - \sum_a \pi_a \nabla \log p_{\theta,a} + 2c\theta. \quad (5.2)$$

价值标签 z 是最终胜负, 搜索叶子使用的是当时网络价值 v ; 两者处在不同时间尺度。训练使新网络拟合实际结果和搜索策略, 再由新网络驱动下一轮搜索, 形成近似广义策略迭代。

6 根节点狄利克雷噪声

探索时根先验常替换为

$$P'(s, a) = (1 - \varepsilon)P(s, a) + \varepsilon \eta_a, \quad \eta \sim \text{Dir}(\alpha, \dots, \alpha). \quad (6.1)$$

对 K 个动作, 对称 Dirichlet 的矩为

$$\mathbb{E} \eta_a = \frac{1}{K}, \quad \text{Var}(\eta_a) = \frac{K-1}{K^2(K\alpha+1)}. \quad (6.2)$$

α 小时样本更尖锐, 鼓励少数随机动作; α 大时接近均匀。混合后

$$\mathbb{E} P'_a = (1 - \varepsilon)P_a + \frac{\varepsilon}{K}, \quad \text{Var}(P'_a) = \varepsilon^2 \text{Var}(\eta_a). \quad (6.3)$$

噪声仅在根加入, 避免整棵树每层都被独立噪声淹没。

7 Bellman 期望方程与优势恒等式

对策略 π , 定义

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s \right], \quad (7.1)$$

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a \right]. \quad (7.2)$$

分离首步奖励:

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s'), \quad (7.3)$$

$$V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot | s)} Q^\pi(s, a). \quad (7.4)$$

优势

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (7.5)$$

在策略动作分布下均值为零:

$$\mathbb{E}_{a \sim \pi} A^\pi(s, a) = 0. \quad (7.6)$$

这不表示每个动作优势小, 只表示正负改进机会按当前策略加权抵消。

8 性能差异引理

令新旧策略为 π', π 。沿 π' 轨迹,

$$\mathbb{E}_{\pi'} \sum_{t=0}^{\infty} \gamma^t A^\pi(s_t, a_t) = \mathbb{E}_{\pi'} \sum_t \gamma^t [r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t)] \quad (8.1)$$

$$= J(\pi') - \mathbb{E} V^\pi(s_0), \quad (8.2)$$

其中价值项望远镜消去, 且有界价值使末项 $\gamma^{T+1} V(s_{T+1}) \rightarrow 0$ 。若初始分布相同, $\mathbb{E} V^\pi(s_0) = J(\pi)$, 故

$$\boxed{J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_{\pi'}, a \sim \pi'} A^\pi(s, a).} \quad (8.3)$$

策略优化代理常把难采样的 $d_{\pi'}$ 替换为旧占用分布 d_π ; 信赖域或比率裁剪的目标是限制这一步替换造成的误差。

9 KL 信赖域的二阶局部形式

对小参数变化 $\Delta\theta$,

$$D_{\text{KL}}(\pi_\theta \| \pi_{\theta+\Delta}) = \frac{1}{2} \Delta^T F(\theta) \Delta + O(\|\Delta\|^3), \quad (9.1)$$

其中 Fisher 信息

$$F(\theta) = \mathbb{E}_{s,a} [\nabla \log \pi_\theta(a | s) \nabla \log \pi_\theta(a | s)^T]. \quad (9.2)$$

一阶目标改进 $g^T \Delta$, 约束 $\frac{1}{2} \Delta^T F \Delta \leq \delta$ 。拉格朗日法:

$$\mathcal{J} = g^T \Delta - \lambda \left(\frac{1}{2} \Delta^T F \Delta - \delta \right). \quad (9.3)$$

驻点

$$g - \lambda F \Delta = 0 \Rightarrow \Delta = \lambda^{-1} F^{-1} g. \quad (9.4)$$

代回约束得到

$$\boxed{\Delta = \sqrt{\frac{2\delta}{g^T F^{-1} g}} F^{-1} g.} \quad (9.5)$$

自然梯度 $F^{-1}g$ 是概率分布几何下最陡方向; PPO 裁剪是更易实现但不严格等价的近似。

10 离策略序列比率的方差

轨迹前 T 步重要性比率

$$W_T = \prod_{t=0}^{T-1} \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}. \quad (10.1)$$

在行为策略 μ 下若支撑相容, $\mathbb{E}_\mu W_T = 1$ 。对数比率是和

$$\log W_T = \sum_t \ell_t, \quad \ell_t = \log \pi(a_t | s_t) - \log \mu(a_t | s_t). \quad (10.2)$$

若粗略假设 ℓ_t 独立、均值 m 、方差 v , 则 W_T 近似 log-normal,

$$\frac{\text{Var}(W_T)}{(\mathbb{E}W_T)^2} \approx e^{Tv} - 1. \quad (10.3)$$

方差随长度指数增长, 这解释了 token/step 级截断、V-trace 或短视野校正的必要性。

截断 $\bar{w}_t = \min(c, w_t)$ 产生偏差, 但单步权重有界, 能控制乘积和梯度爆炸。偏差精确来自尾部

$$\mathbb{E}_\mu[(w_t - c)_+ f_t]. \quad (10.4)$$

11 熵正则的策略梯度

状态熵

$$\mathcal{H}(\pi_\theta) = - \sum_a \pi_\theta(a) \log \pi_\theta(a). \quad (11.1)$$

求导

$$\nabla \mathcal{H} = - \sum_a \nabla \pi(a) [1 + \log \pi(a)] \quad (11.2)$$

$$= -\mathbb{E}_{a \sim \pi}[(1 + \log \pi(a)) \nabla \log \pi(a)]. \quad (11.3)$$

因 $\mathbb{E} \nabla \log \pi = 0$, 常数 1 可去掉:

$$\nabla \mathcal{H} = -\mathbb{E}[\log \pi(a) \nabla \log \pi(a)]. \quad (11.4)$$

加入 $+\alpha \mathcal{H}$ 会提高低概率动作的相对激励, 防止策略过早坍缩; 但在可验证答案任务中, 过强熵也会降低正确答案集中度。

12 奖励平移、缩放与归一化

若所有奖励加常数 c , 无限折扣回报

$$G'_t = G_t + \frac{c}{1 - \gamma}. \quad (12.1)$$

精确优势不变, 因为 Q, V 同时加 $c/(1 - \gamma)$ 。用采样回报而无正确基线时, 常数会增加梯度方差但期望 score 项仍抵消。

奖励乘正数 a 时, 优势和策略梯度乘 a , 等价于改变有效学习率; PPO 的裁剪边界不随 a 变, 所以裁剪区域不变但目标梯度尺度变。组内标准化

$$\hat{A}_i = \frac{R_i - \bar{R}}{s_R + \epsilon} \quad (12.2)$$

同时消除平移并近似消除尺度, 但 s_R 很小时会放大噪声, 故需要 ϵ 或跳过全同奖励组。

13 KL 正则与奖励塑形

目标

$$J(\pi) = \mathbb{E}_\pi[R] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}) \quad (13.1)$$

可写为每步塑形奖励

$$r'_t = r_t - \beta [\log \pi(a_t | s_t) - \log \pi_{\text{ref}}(a_t | s_t)]. \quad (13.2)$$

固定状态、给定动作价值 $Q(a)$ 时，最优非参数策略由拉格朗日法得到

$$\pi^*(a) = \frac{\pi_{\text{ref}}(a) e^{Q(a)/\beta}}{\sum_b \pi_{\text{ref}}(b) e^{Q(b)/\beta}}. \quad (13.3)$$

$\beta \rightarrow 0$ 时集中到高价值动作， $\beta \rightarrow \infty$ 时回到参考策略。参考策略为零概率的动作在正向 KL 约束下永远不可选，故支撑选择很重要。

14 拒答动作与错误成本

设回答正确收益 u_c 、错误收益 u_e 、拒答收益 u_a ，模型置信度 $p = \mathbb{P}(\text{correct} | s)$ 。回答期望效用

$$U_{\text{ans}}(p) = pu_c + (1-p)u_e, \quad (14.1)$$

拒答效用 $U_{\text{abstain}} = u_a$ 。当

$$p \geq \frac{u_a - u_e}{u_c - u_e} \quad (14.2)$$

时回答更优（假设 $u_c > u_e$ ）。因此最优置信阈值由错误和拒答的相对成本决定，不是固定的 1/2。RL 后训练若隐含奖励给拒答过低分，就会系统性鼓励猜测。

15 有限 horizon 的回报界

若 $|r_t| \leq R_{\text{max}}$ ，无限折扣回报有界

$$|G_t| \leq \sum_{k=0}^{\infty} \gamma^k R_{\text{max}} = \frac{R_{\text{max}}}{1-\gamma}. \quad (15.1)$$

截断到 H 步的尾部误差

$$\left| G_t - \sum_{k=0}^{H-1} \gamma^k r_{t+k} \right| \leq \frac{\gamma^H R_{\text{max}}}{1-\gamma}. \quad (15.2)$$

要使其不超过 ϵ ，充分条件

$$H \geq \frac{\log[\epsilon(1-\gamma)/R_{\text{max}}]}{\log \gamma}, \quad (15.3)$$

注意 $\log \gamma < 0$ ，除法会反转不等号，右端为正。

16 光滑损失的下降引理

若 L 的梯度是 β -Lipschitz:

$$\|\nabla L(x) - \nabla L(y)\| \leq \beta \|x - y\|, \quad (16.1)$$

则沿线段积分

$$L(y) - L(x) = \int_0^1 \nabla L(x + t(y-x))^T (y-x) dt \quad (16.2)$$

$$= \nabla L(x)^T (y-x) + R, \quad (16.3)$$

余项满足

$$|R| \leq \int_0^1 \beta t \|y - x\|^2 dt = \frac{\beta}{2} \|y - x\|^2. \quad (16.4)$$

故下降引理

$$L(y) \leq L(x) + \nabla L(x)^T (y - x) + \frac{\beta}{2} \|y - x\|^2. \quad (16.5)$$

取梯度步 $y = x - \eta \nabla L(x)$:

$$L(y) \leq L(x) - \eta \left(1 - \frac{\beta\eta}{2}\right) \|\nabla L(x)\|^2. \quad (16.6)$$

当 $0 < \eta < 2/\beta$ 时每个精确梯度步下降；深网中 β 未知且随位置变化，这仍解释了学习率过大造成不稳定的局部机制。

17 二阶近似与曲率方向

在 x 附近 Taylor 展开

$$L(x + \Delta) = L(x) + g^T \Delta + \frac{1}{2} \Delta^T H \Delta + O(\|\Delta\|^3). \quad (17.1)$$

若 $H = U \text{diag}(\lambda_i) U^T$ ，在本征方向 u_i 上步长 a 的变化

$$\Delta L \approx a g_i + \frac{1}{2} \lambda_i a^2. \quad (17.2)$$

$\lambda_i > 0$ 为局部碗形， $\lambda_i < 0$ 是负曲率逃离鞍点方向。加阻尼的 Newton 步

$$\Delta = -(H + \lambda I)^{-1} g \quad (17.3)$$

在特征方向缩放为 $-g_i/(\lambda_i + \lambda)$ ，避免接近零或负特征值造成巨大步长。

18 链式 Jacobian 与条件数

复合映射 $y = f_L \circ \dots \circ f_1(x)$ 的 Jacobian

$$J_{y \leftarrow x} = J_L J_{L-1} \dots J_1. \quad (18.1)$$

谱范数上界

$$\|J_{y \leftarrow x}\|_2 \leq \prod_{\ell=1}^L \|J_\ell\|_2. \quad (18.2)$$

若各层最小奇异值存在，

$$\sigma_{\min}(J_{y \leftarrow x}) \geq \prod_{\ell} \sigma_{\min}(J_\ell). \quad (18.3)$$

因此条件数至多乘法累积：

$$\kappa(J_{y \leftarrow x}) \leq \prod_{\ell} \kappa(J_\ell). \quad (18.4)$$

低维映射、递归模块和物理传播都面临同一问题：表示存在不代表反向梯度数值良态。

19 随机梯度的偏差与方差

设样本梯度 $g(\theta; \xi)$ 满足

$$\mathbb{E}_{\xi} g(\theta; \xi) = \nabla L(\theta), \quad \mathbb{E} \|g - \nabla L\|^2 \leq \sigma^2. \quad (19.1)$$

独立批量 B 的平均

$$\bar{g}_B = \frac{1}{B} \sum_{i=1}^B g_i \quad (19.2)$$

满足

$$\mathbb{E} \bar{g}_B = \nabla L, \quad \mathbb{E} \|\bar{g}_B - \nabla L\|^2 \leq \frac{\sigma^2}{B}. \quad (19.3)$$

若样本相关，协方差项出现：

$$\text{Var}(\bar{g}_B) = \frac{1}{B^2} \left[\sum_i \text{Var}(g_i) + \sum_{i \neq j} \text{Cov}(g_i, g_j) \right]. \quad (19.4)$$

扩大批量只有在交叉协方差不主导时才近似按 $1/B$ 降噪。

若使用有偏估计 $\mathbb{E} \hat{g} = \nabla L + b$ ，均方误差分解

$$\mathbb{E} \|\hat{g} - \nabla L\|^2 = \|b\|^2 + \text{tr Cov}(\hat{g}). \quad (19.5)$$

直通估计、停止梯度目标和截断反传通常以可控偏差换低方差或低内存。

20 Adam 的尺度归一化

逐坐标 Adam 更新

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (20.1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (20.2)$$

$$\hat{m}_t = m_t / (1 - \beta_1^t), \quad (20.3)$$

$$\hat{v}_t = v_t / (1 - \beta_2^t), \quad (20.4)$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (20.5)$$

若梯度长期乘常数 $c > 0$ ，忽略 ϵ 时 $\hat{m}$ 乘 c 、 $\sqrt{\hat{v}}$ 也乘 c ，更新近似不变。但瞬态、符号变化和 ϵ 会破坏精确尺度不变性。

AdamW 把权重衰减解耦：

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (20.6)$$

这不同于把 $\lambda\theta$ 加入梯度后再经过自适应分母；后者会按坐标二阶矩缩放正则化。

21 范数约束与投影梯度

约束集合 C 上的投影梯度

$$\theta^+ = \Pi_C(\theta - \eta g), \quad \Pi_C(x) = \arg \min_{y \in C} \|x - y\|^2. \quad (21.1)$$

对欧氏球 $C = \{x : \|x\| \leq R\}$,

$$\Pi_C(x) = \begin{cases} x, & \|x\| \leq R, \\ Rx/\|x\|, & \|x\| > R. \end{cases} \quad (21.2)$$

对流形约束，局部一阶步先投影到切空间，再用 retraction 回到流形；仅把参数写成 $g(z)$ 相当于用参数化隐式满足约束，但会引入 $J_g^T J_g$ 的坐标度量。

22 Lipschitz 误差的层间传播

真实模块 f_ℓ 、近似模块 $\hat{f}_\ell$ 满足

$$\|f_\ell(x) - \hat{f}_\ell(x)\| \leq \epsilon_\ell, \quad \|f_\ell(x) - f_\ell(y)\| \leq L_\ell \|x - y\|. \quad (22.1)$$

令真实、近似中间状态差 e_ℓ 。三角不等式给出

$$e_{\ell+1} = \|f_\ell(h_\ell) - \hat{f}_\ell(\hat{h}_\ell)\| \quad (22.2)$$

$$\leq L_\ell e_\ell + \epsilon_\ell. \quad (22.3)$$

递归展开

$$e_L \leq \left(\prod_{j=0}^{L-1} L_j \right) e_0 + \sum_{\ell=0}^{L-1} \left(\prod_{j=\ell+1}^{L-1} L_j \right) \epsilon_\ell. \quad (22.4)$$

早期层误差乘更多后续 Lipschitz 因子，所以量化、低秩近似或局部训练的相同单层误差，放在不同深度并不等价。

23 复杂度必须区分四个量

参数量、FLOPs、激活内存和通信量是不同指标。以线性层 $Y = XW$ 、 $X \in \mathbb{R}^{B \times n}$ 、 $W \in \mathbb{R}^{n \times m}$ 为例：

$$\text{参数量} = nm, \quad (23.1)$$

$$\text{前向乘加量} \asymp Bnm, \quad (23.2)$$

$$\text{主要激活量} = B(n + m), \quad (23.3)$$

$$\text{数据并行梯度通信} \asymp nm. \quad (23.4)$$

低秩因子可同时减少参数与乘法，但动态稀疏若实现仍做稠密 kernel，参数/FLOPs 公式不会自动转化为墙钟加速。冻结参数减少梯度和优化器状态，却不一定减少前向计算或输入梯度计算。