

# 5-1801.01290v2-Reinforcement-SAC

## 1 符号与维度

| 符号                 | 维度                    | 含义                |
|--------------------|-----------------------|-------------------|
| $\pi, Q, V$        | --                    | 随机策略、软动作价值与软状态价值。 |
| $\alpha$           | $\mathbb{R}_{>0}$     | 熵温度。              |
| $\mathcal{H}(\pi)$ | $\mathbb{R}_{\geq 0}$ | 策略熵。              |
| $\gamma$           | $[0, 1)$              | 折扣因子。             |

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

## 2 最大熵目标与软 Bellman 方程

最大熵强化学习优化

$$J(\pi) = \mathbb{E}_{\pi} \sum_{t=0}^{\infty} \gamma^t [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))]. \quad (2.1)$$

因  $\mathcal{H}(\pi(\cdot | s)) = -\mathbb{E}_{a \sim \pi} \log \pi(a | s)$ ，定义软状态价值

$$V^{\pi}(s) = \mathbb{E}_{a \sim \pi} [Q^{\pi}(s, a) - \alpha \log \pi(a | s)]. \quad (2.2)$$

从第一步分离回报，得到软 Bellman 期望方程

$$Q^{\pi}(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^{\pi}(s'). \quad (2.3)$$

相应软 Bellman 算子

$$(T^{\pi}Q)(s, a) = r(s, a) + \gamma \mathbb{E}_{s', a'} [Q(s', a') - \alpha \log \pi(a' | s')] \quad (2.4)$$

对两个  $Q$  的差仍是  $\gamma$  压缩，因为熵项抵消：

$$\|T^{\pi}Q_1 - T^{\pi}Q_2\|_{\infty} \leq \gamma \|Q_1 - Q_2\|_{\infty}. \quad (2.5)$$

## 3 Boltzmann 最优策略与 KL 投影

固定状态和  $Q$ ，策略改进问题为

$$\max_{\pi} \sum_a \pi(a) Q(a) + \alpha \mathcal{H}(\pi), \quad \text{s.t.} \quad \sum_a \pi(a) = 1. \quad (3.1)$$

拉格朗日函数

$$\mathcal{J} = \sum_a \pi(a) Q(a) - \alpha \sum_a \pi(a) \log \pi(a) + \lambda \left( \sum_a \pi(a) - 1 \right). \quad (3.2)$$

一阶条件为

$$Q(a) - \alpha(1 + \log \pi(a)) + \lambda = 0, \quad (3.3)$$

故

$$\pi^*(a | s) = \frac{\exp(Q(s, a)/\alpha)}{\sum_b \exp(Q(s, b)/\alpha)}. \quad (3.4)$$

连续动作时分母成为配分函数  $Z(s) = \int \exp(Q(s, a)/\alpha) da$ 。

对参数化策略，最小化

$$D_{\text{KL}} \left( \pi_{\theta}(\cdot | s) \left\| \frac{\exp(Q(s, \cdot)/\alpha)}{Z(s)} \right\| \right) \quad (3.5)$$

展开得

$$D_{\text{KL}} = \mathbb{E}_{a \sim \pi_{\theta}} \left[ \log \pi_{\theta}(a | s) - \frac{1}{\alpha} Q(s, a) + \log Z(s) \right]. \quad (3.6)$$

乘  $\alpha$  并去掉与  $\theta$  无关的  $\alpha \log Z(s)$ ，得到 actor 损失

$$J_{\pi}(\theta) = \mathbb{E}[\alpha \log \pi_{\theta}(a | s) - Q(s, a)]. \quad (3.7)$$

## 4 重参数化策略梯度

高斯策略通过

$$u = \mu_{\theta}(s) + \sigma_{\theta}(s) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I), \quad a = \tanh u \quad (4.1)$$

重参数化。把随机性移到与  $\theta$  无关的  $\epsilon$  后，

$$\nabla_{\theta} J_{\pi} = \mathbb{E}_{s, \epsilon} \nabla_{\theta} [\alpha \log \pi_{\theta}(f_{\theta}(\epsilon; s) | s) - Q_{\phi}(s, f_{\theta}(\epsilon; s))]. \quad (4.2)$$

第二项的路径导数为

$$-\nabla_a Q_{\phi}(s, a) \frac{\partial f_{\theta}}{\partial \theta}, \quad (4.3)$$

比纯 score-function 估计通常方差更低。

由于  $a = \tanh u$ ，密度需作变量变换：

$$\log \pi(a | s) = \log \mathcal{N}(u; \mu, \sigma^2) - \sum_j \log(1 - \tanh^2 u_j). \quad (4.4)$$

第二项是 Jacobian 行列式校正；省略会使边界附近的动作密度错误。

## 5 双 critic 与最小值偏差

SAC 常使用两个估计  $Q_{\phi_1}, Q_{\phi_2}$ ，目标取

$$y = r + \gamma(1 - d) \left[ \min_{i=1,2} Q_{\phi_i}(s', a') - \alpha \log \pi(a' | s') \right]. \quad (5.1)$$

若  $Q_i = Q^* + \epsilon_i$  且误差独立同分布、均值零，则

$$\mathbb{E} \min(Q_1, Q_2) = Q^* + \mathbb{E} \min(\epsilon_1, \epsilon_2) \leq Q^*. \quad (5.2)$$

最小值把最大化产生的正偏差换成保守的负偏差。两个 critic 高度相关时，校正效果会减弱。

critic 损失为

$$J_Q(\phi_i) = \frac{1}{2} \mathbb{E}(Q_{\phi_i}(s, a) - \text{sg}(y))^2, \quad (5.3)$$

故

$$\nabla_{\phi_i} J_Q = \mathbb{E}[(Q_{\phi_i} - y) \nabla_{\phi_i} Q_{\phi_i}]. \quad (5.4)$$

目标动作与目标 critic 都停止梯度，形成稳定的半梯度更新。

## 6 温度参数的对偶推导

希望平均熵不低于目标  $\mathcal{H}_0$ :

$$\mathbb{E}[-\log \pi(a | s)] \geq \mathcal{H}_0. \quad (6.1)$$

写成约束  $g(\pi) = \mathcal{H}_0 + \mathbb{E} \log \pi \leq 0$ , 拉格朗日乘子  $\alpha \geq 0$ 。对固定策略, 温度的对偶目标可写为

$$J(\alpha) = \mathbb{E}_{a \sim \pi}[-\alpha(\log \pi(a | s) + \mathcal{H}_0)]. \quad (6.2)$$

其梯度

$$\frac{\partial J}{\partial \alpha} = -\mathbb{E}[\log \pi(a | s) + \mathcal{H}_0]. \quad (6.3)$$

若当前熵  $-\mathbb{E} \log \pi$  小于目标, 括号期望为正, 梯度下降增大  $\alpha$ , 从而更重视熵; 方向与约束一致。

为自动满足  $\alpha > 0$ , 令  $\alpha = e^\eta$ 。链式法则给出

$$\frac{\partial J}{\partial \eta} = -\alpha \mathbb{E}[\log \pi(a | s) + \mathcal{H}_0]. \quad (6.4)$$

实践中也常直接对  $\eta$  使用去掉前置  $\alpha$  的等价尺度目标; 这会改变步长但保留驻点。

## 7 Bellman 期望方程与优势恒等式

对策略  $\pi$ , 定义

$$V^\pi(s) = \mathbb{E}_\pi \left[ \sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s \right], \quad (7.1)$$

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[ \sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s, a_0 = a \right]. \quad (7.2)$$

分离首步奖励:

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s'), \quad (7.3)$$

$$V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot | s)} Q^\pi(s, a). \quad (7.4)$$

优势

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (7.5)$$

在策略动作分布下均值为零:

$$\mathbb{E}_{a \sim \pi} A^\pi(s, a) = 0. \quad (7.6)$$

这不表示每个动作优势小, 只表示正负改进机会按当前策略加权抵消。

## 8 性能差异引理

令新旧策略为  $\pi', \pi$ 。沿  $\pi'$  轨迹,

$$\mathbb{E}_{\pi'} \sum_{t=0}^{\infty} \gamma^t A^\pi(s_t, a_t) = \mathbb{E}_{\pi'} \sum_t \gamma^t [r_t + \gamma V^\pi(s_{t+1}) - V^\pi(s_t)] \quad (8.1)$$

$$= J(\pi') - \mathbb{E} V^\pi(s_0), \quad (8.2)$$

其中价值项望远镜消去, 且有界价值使末项  $\gamma^{T+1} V(s_{T+1}) \rightarrow 0$ 。若初始分布相同,  $\mathbb{E} V^\pi(s_0) = J(\pi)$ , 故

$$\boxed{J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_{\pi'}, a \sim \pi'} A^\pi(s, a).} \quad (8.3)$$

策略优化代理常把难采样的  $d_{\pi'}$  替换为旧占用分布  $d_\pi$ ; 信赖域或比率裁剪的目标是限制这一步替换造成的误差。

## 9 KL 信赖域的二阶局部形式

对小参数变化  $\Delta\theta$ ,

$$D_{\text{KL}}(\pi_\theta \| \pi_{\theta+\Delta}) = \frac{1}{2} \Delta^T F(\theta) \Delta + O(\|\Delta\|^3), \quad (9.1)$$

其中 Fisher 信息

$$F(\theta) = \mathbb{E}_{s,a} [\nabla \log \pi_\theta(a | s) \nabla \log \pi_\theta(a | s)^T]. \quad (9.2)$$

一阶目标改进  $g^T \Delta$ , 约束  $\frac{1}{2} \Delta^T F \Delta \leq \delta$ 。拉格朗日法:

$$\mathcal{J} = g^T \Delta - \lambda \left( \frac{1}{2} \Delta^T F \Delta - \delta \right). \quad (9.3)$$

驻点

$$g - \lambda F \Delta = 0 \Rightarrow \Delta = \lambda^{-1} F^{-1} g. \quad (9.4)$$

代回约束得到

$$\Delta = \sqrt{\frac{2\delta}{g^T F^{-1} g}} F^{-1} g. \quad (9.5)$$

自然梯度  $F^{-1}g$  是概率分布几何下最陡方向; PPO 裁剪是更易实现但不严格等价的近似。

## 10 离策略序列比率的方差

轨迹前  $T$  步重要性比率

$$W_T = \prod_{t=0}^{T-1} \frac{\pi(a_t | s_t)}{\mu(a_t | s_t)}. \quad (10.1)$$

在行为策略  $\mu$  下若支撑相容,  $\mathbb{E}_\mu W_T = 1$ 。对数比率是和

$$\log W_T = \sum_t \ell_t, \quad \ell_t = \log \pi(a_t | s_t) - \log \mu(a_t | s_t). \quad (10.2)$$

若粗略假设  $\ell_t$  独立、均值  $m$ 、方差  $v$ , 则  $W_T$  近似 log-normal,

$$\frac{\text{Var}(W_T)}{(\mathbb{E}W_T)^2} \approx e^{Tv} - 1. \quad (10.3)$$

方差随长度指数增长, 这解释了 token/step 级截断、V-trace 或短视野校正的必要性。

截断  $\bar{w}_t = \min(c, w_t)$  产生偏差, 但单步权重有界, 能控制乘积和梯度爆炸。偏差精确来自尾部

$$\mathbb{E}_\mu[(w_t - c)_+ f_t]. \quad (10.4)$$

## 11 熵正则的策略梯度

状态熵

$$\mathcal{H}(\pi_\theta) = - \sum_a \pi_\theta(a) \log \pi_\theta(a). \quad (11.1)$$

求导

$$\nabla \mathcal{H} = - \sum_a \nabla \pi(a) [1 + \log \pi(a)] \quad (11.2)$$

$$= - \mathbb{E}_{a \sim \pi} [(1 + \log \pi(a)) \nabla \log \pi(a)]. \quad (11.3)$$

因  $\mathbb{E} \nabla \log \pi = 0$ , 常数 1 可去掉:

$$\nabla \mathcal{H} = - \mathbb{E} [\log \pi(a) \nabla \log \pi(a)]. \quad (11.4)$$

加入  $+\alpha \mathcal{H}$  会提高低概率动作的相对激励, 防止策略过早坍缩; 但在可验证答案任务中, 过强熵也会降低正确答案集中度。

## 12 奖励平移、缩放与归一化

若所有奖励加常数  $c$ ，无限折扣回报

$$G'_t = G_t + \frac{c}{1-\gamma}. \quad (12.1)$$

精确优势不变，因为  $Q, V$  同时加  $c/(1-\gamma)$ 。用采样回报而无正确基线时，常数会增加梯度方差但期望 score 项仍抵消。

奖励乘正数  $a$  时，优势和策略梯度乘  $a$ ，等价于改变有效学习率；PPO 的裁剪边界不随  $a$  变，所以裁剪区域不变但目标梯度尺度变。组内标准化

$$\hat{A}_i = \frac{R_i - \bar{R}}{s_R + \epsilon} \quad (12.2)$$

同时消除平移并近似消除尺度，但  $s_R$  很小时会放大噪声，故需要  $\epsilon$  或跳过全同奖励组。

## 13 KL 正则与奖励塑形

目标

$$J(\pi) = \mathbb{E}_\pi[R] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}) \quad (13.1)$$

可写为每步塑形奖励

$$r'_t = r_t - \beta [\log \pi(a_t | s_t) - \log \pi_{\text{ref}}(a_t | s_t)]. \quad (13.2)$$

固定状态、给定动作价值  $Q(a)$  时，最优非参数策略由拉格朗日法得到

$$\pi^*(a) = \frac{\pi_{\text{ref}}(a) e^{Q(a)/\beta}}{\sum_b \pi_{\text{ref}}(b) e^{Q(b)/\beta}}. \quad (13.3)$$

$\beta \rightarrow 0$  时集中到高价值动作， $\beta \rightarrow \infty$  时回到参考策略。参考策略为零概率的动作在正向 KL 约束下永远不可选，故支撑选择很重要。

## 14 拒答动作与错误成本

设回答正确收益  $u_c$ 、错误收益  $u_e$ 、拒答收益  $u_a$ ，模型置信度  $p = \mathbb{P}(\text{correct} | s)$ 。回答期望效用

$$U_{\text{ans}}(p) = pu_c + (1-p)u_e, \quad (14.1)$$

拒答效用  $U_{\text{abstain}} = u_a$ 。当

$$p \geq \frac{u_a - u_e}{u_c - u_e} \quad (14.2)$$

时回答更优（假设  $u_c > u_e$ ）。因此最优置信阈值由错误和拒答的相对成本决定，不是固定的  $1/2$ 。RL 后训练若隐含奖励给拒答过低分，就会系统性鼓励猜测。

## 15 有限 horizon 的回报界

若  $|r_t| \leq R_{\text{max}}$ ，无限折扣回报有界

$$|G_t| \leq \sum_{k=0}^{\infty} \gamma^k R_{\text{max}} = \frac{R_{\text{max}}}{1-\gamma}. \quad (15.1)$$

截断到  $H$  步的尾部误差

$$\left| G_t - \sum_{k=0}^{H-1} \gamma^k r_{t+k} \right| \leq \frac{\gamma^H R_{\text{max}}}{1-\gamma}. \quad (15.2)$$

要使其不超过  $\epsilon$ ，充分条件

$$H \geq \frac{\log[\epsilon(1-\gamma)/R_{\max}]}{\log \gamma}, \quad (15.3)$$

注意  $\log \gamma < 0$ ，除法会反转不等号，右端为正。