

# 6-2412.19437v2-Integrated-DeepseekV3

## 1 符号与维度

| 符号         | 维度                          | 含义                       |
|------------|-----------------------------|--------------------------|
| $X$        | $\mathbb{R}^{T \times d}$   | 长度为 $T$ 的隐藏状态序列。         |
| $Q, K, V$  | $\mathbb{R}^{T \times d_h}$ | 查询、键和值。                  |
| $A$        | $\mathbb{R}^{T \times T}$   | 行归一化注意力矩阵。               |
| $M$        | $\mathbb{R}^{T \times T}$   | 因果或结构掩码。                 |
| $H, d_h$   | $\mathbb{N}$                | 注意力头数与单头维度, $Hd_h = d$ 。 |
| $c_t^{KV}$ | $\mathbb{R}^{d_c}$          | MLA 压缩 KV 潜变量。           |
| $b_i$      | $\mathbb{R}$                | 无辅助损失负载平衡偏置。             |
| $D$        | $\mathbb{N}$                | 多 token 预测深度。            |

所有向量默认是列向量；未特别说明时，期望同时对数据、噪声和采样时刻取值。下文只展开论文中承担方法逻辑的公式，并把所需假设写在推导发生的位置。

## 2 缩放点积注意力的逐项推导

设单头输入为  $X \in \mathbb{R}^{n \times d}$ ，投影矩阵为  $W_Q, W_K \in \mathbb{R}^{d \times d_k}$ 、 $W_V \in \mathbb{R}^{d \times d_v}$ 。于是

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V, \quad S = \frac{QK^T}{\sqrt{d_k}}, \quad P = \text{softmax}_{\text{row}}(S), \quad O = PV. \quad (2.1)$$

维度依次为  $Q, K \in \mathbb{R}^{n \times d_k}$ 、 $S, P \in \mathbb{R}^{n \times n}$ 、 $V, O \in \mathbb{R}^{n \times d_v}$ 。

### 2.1 为什么除以 $\sqrt{d_k}$

令某一对 query、key 的坐标独立、均值为零、方差为  $\sigma^2$ ，则

$$q^T k = \sum_{a=1}^{d_k} q_a k_a, \quad (2.2)$$

$$\mathbb{E}[q^T k] = \sum_a \mathbb{E}[q_a] \mathbb{E}[k_a] = 0, \quad (2.3)$$

$$\text{Var}(q^T k) = \sum_a \text{Var}(q_a k_a) = \sum_a \mathbb{E}[q_a^2] \mathbb{E}[k_a^2] = d_k \sigma^4. \quad (2.4)$$

因此未缩放 logit 的标准差为  $\sqrt{d_k} \sigma^2$ ；缩放后

$$\text{Var}\left(\frac{q^T k}{\sqrt{d_k}}\right) = \sigma^4. \quad (2.5)$$

这不是让注意力必然均匀，而是避免初始化时维度增大直接把 softmax 推入饱和区。

### 2.2 softmax Jacobian 的完整形式

对一行  $p_i = e^{s_i} / Z$ ， $Z = \sum_j e^{s_j}$ 。逐坐标求导得

$$\frac{\partial p_i}{\partial s_j} = \frac{\delta_{ij} e^{s_i} Z - e^{s_i} e^{s_j}}{Z^2} \quad (2.6)$$

$$= p_i (\delta_{ij} - p_j). \quad (2.7)$$

写成矩阵即

$$J_{\text{sm}}(p) = \text{diag}(p) - pp^T. \quad (2.8)$$

它是半正定矩阵，因为任意  $z$  满足

$$z^T J_{\text{sm}}(p) z = \sum_i p_i z_i^2 - \left( \sum_i p_i z_i \right)^2 \quad (2.9)$$

$$= \text{Var}_{i \sim p}(z_i) \geq 0. \quad (2.10)$$

又因  $J_{\text{sm}}(p)\mathbf{1} = 0$ ，给所有 logit 加同一常数不改变 softmax。

设损失对输出一行的梯度为  $g_o \in \mathbb{R}^{d_v}$ 。由  $o = \sum_j p_j v_j$ ，

$$\frac{\partial \mathcal{L}}{\partial p_j} = g_o^T v_j, \quad (2.11)$$

$$\frac{\partial \mathcal{L}}{\partial s_j} = \sum_i \frac{\partial \mathcal{L}}{\partial p_i} \frac{\partial p_i}{\partial s_j} \quad (2.12)$$

$$= p_j g_o^T (v_j - o). \quad (2.13)$$

所以一个 key 的梯度由它相对当前加权均值  $o$  的偏差决定；这给出了注意力各位置梯度耦合的精确来源。

### 2.3 对 $Q, K, V$ 的矩阵梯度

记  $G_O = \partial \mathcal{L} / \partial O$ 。矩阵微分

$$dO = dP V + P dV \quad (2.14)$$

与 Frobenius 内积  $d\mathcal{L} = \langle G_O, dO \rangle_F$  给出

$$G_V = P^T G_O, \quad G_P = G_O V^T. \quad (2.15)$$

对每行应用 softmax Jacobian，令

$$G_S = P \odot \left( G_P - ((G_P \odot P)\mathbf{1})\mathbf{1}^T \right), \quad (2.16)$$

其中括号中的列向量在行内广播。再由

$$dS = \frac{dQ K^T + Q dK^T}{\sqrt{d_k}} \quad (2.17)$$

得到

$$\boxed{G_Q = \frac{G_S K}{\sqrt{d_k}}, \quad G_K = \frac{G_S^T Q}{\sqrt{d_k}}, \quad G_V = P^T G_O.} \quad (2.18)$$

最后通过  $Q = XW_Q$  等式继续链式求导：

$$G_{W_Q} = X^T G_Q, \quad G_X^{(Q)} = G_Q W_Q^T, \quad (2.19)$$

$$G_{W_K} = X^T G_K, \quad G_X^{(K)} = G_K W_K^T, \quad (2.20)$$

$$G_{W_V} = X^T G_V, \quad G_X^{(V)} = G_V W_V^T. \quad (2.21)$$

同一输入同时产生三条梯度路径，故  $G_X = G_X^{(Q)} + G_X^{(K)} + G_X^{(V)}$ 。

### 3 掩码、稀疏化与复杂度

令二值可见性矩阵  $M \in \{0, 1\}^{n \times n}$ 。严格掩码写成

$$\tilde{S}_{ij} = \begin{cases} S_{ij}, & M_{ij} = 1, \\ -\infty, & M_{ij} = 0, \end{cases} \quad \tilde{P}_{ij} = \frac{M_{ij} e^{S_{ij}}}{\sum_{\ell} M_{i\ell} e^{S_{i\ell}}}. \quad (3.1)$$

因此被掩码项的概率与梯度都严格为零。若第  $i$  行只保留  $s_i$  个 key，注意力乘法量为

$$\Theta \left( d_k \sum_i s_i + d_v \sum_i s_i \right). \quad (3.2)$$

稠密情形  $s_i = n$  为  $\Theta(n^2(d_k + d_v))$ ；若  $s_i \leq s \ll n$ ，则为  $\Theta(ns(d_k + d_v))$ 。但只有稀疏索引和 kernel 真正跳过零块时，理论乘法量才会转化为实际加速。

#### 3.1 稀疏截断的输出误差

对一行概率  $p$ ，保留集合  $S$ ，被删除概率质量  $\varepsilon = \sum_{j \notin S} p_j$ 。重新归一化后

$$\hat{p}_j = \begin{cases} p_j / (1 - \varepsilon), & j \in S, \\ 0, & j \notin S. \end{cases} \quad (3.3)$$

直接计算其  $\ell_1$  距离：

$$\|p - \hat{p}\|_1 = \sum_{j \in S} p_j \frac{\varepsilon}{1 - \varepsilon} + \sum_{j \notin S} p_j \quad (3.4)$$

$$= \varepsilon + \varepsilon = 2\varepsilon. \quad (3.5)$$

若  $\|v_j\|_2 \leq V_{\max}$ ，则输出误差满足

$$\|o - \hat{o}\|_2 = \left\| \sum_j (p_j - \hat{p}_j) v_j \right\|_2 \leq 2\varepsilon V_{\max}. \quad (3.6)$$

这说明 top- $k$  的关键不是  $k$  本身，而是被丢弃的注意力质量。

#### 3.2 KV 缓存的精确规模

自回归解码第  $t$  步只新增一个 key/value。若有  $L$  层、 $h_{kv}$  个 KV 头、每头维度  $d_h$ 、每元素  $b$  字节，则缓存量为

$$\text{Mem}_{KV} = 2Lth_{kv}d_hb. \quad (3.7)$$

其中因子 2 来自 key 与 value。多查询或分组查询通过令  $h_{kv} < h_q$  降低缓存；它改变的是存储与带宽，不改变 query 头的数量。

### 4 残差路径与归一化的稳定性

对 pre-norm 块

$$x_{\ell+1} = x_{\ell} + F_{\ell}(\text{LN}(x_{\ell})), \quad (4.1)$$

Jacobian 为

$$\frac{\partial x_{\ell+1}}{\partial x_{\ell}} = I + J_{F_{\ell}} J_{\text{LN}}. \quad (4.2)$$

跨  $L$  层梯度是这些矩阵的乘积。与没有残差时只乘  $J_{F_\ell} J_{\text{LN}}$  相比，恒等项提供直接通路。若  $\|J_{F_\ell} J_{\text{LN}}\|_2 \leq \eta_\ell$ ，则

$$\left\| \prod_{\ell=1}^L (I + A_\ell) \right\|_2 \leq \prod_{\ell=1}^L (1 + \eta_\ell) \leq \exp\left(\sum_{\ell=1}^L \eta_\ell\right). \quad (4.3)$$

这给出稳定性的充分条件；它不是“残差必然防止爆炸”的无条件结论。

对向量  $x \in \mathbb{R}^d$ ，忽略可学习仿射项时

$$\mu = \frac{1}{d} \mathbf{1}^\top x, \quad \sigma^2 = \frac{1}{d} \|x - \mu \mathbf{1}\|_2^2, \quad y = \frac{x - \mu \mathbf{1}}{\sqrt{\sigma^2 + \epsilon}}. \quad (4.4)$$

令  $P_c = I - \frac{1}{d} \mathbf{1} \mathbf{1}^\top$ 、 $u = P_c x$ 、 $s = \sqrt{d^{-1} u^\top u + \epsilon}$ ，则逐步微分得

$$du = P_c dx, \quad (4.5)$$

$$ds = \frac{u^\top du}{ds}, \quad (4.6)$$

$$dy = \frac{1}{s} P_c dx - \frac{u u^\top P_c dx}{ds^3}, \quad (4.7)$$

故

$$J_{\text{LN}} = \frac{1}{s} P_c - \frac{u u^\top}{ds^3}. \quad (4.8)$$

该式显示归一化会消除全常数方向，并对样本方差方向施加额外投影。

## 5 多头分解与合并

第  $a$  个头输出  $O_a = P_a V_a \in \mathbb{R}^{n \times d_h}$ ，拼接后

$$Y = [O_1 \| \cdots \| O_h] W_O, \quad W_O \in \mathbb{R}^{hd_h \times d}. \quad (5.1)$$

因此多头不是把概率矩阵简单平均，而是在不同投影子空间中分别形成概率矩阵，再由  $W_O$  线性混合。参数量（忽略偏置）为

$$d(hd_k) + d(hd_k) + d(hd_v) + (hd_v)d. \quad (5.2)$$

常用  $hd_k = hd_v = d$  时等于  $4d^2$ 。注意力矩阵的主内存项仍为  $hn^2$ ；Flash 类实现通过分块在线维护 softmax 的行最大值与归一化和，避免物化完整矩阵，但其数学输出仍与上述 softmax 等价。

## 6 自回归似然与 token 梯度

对序列  $x_{1:T}$ ，因果语言模型按概率链式法则分解

$$p_\theta(x_{1:T}) = \prod_{t=1}^T p_\theta(x_t | x_{<t}). \quad (6.1)$$

负对数似然

$$\mathcal{L}_{\text{NLL}} = - \sum_{t=1}^T \log p_\theta(x_t | x_{<t}). \quad (6.2)$$

若第  $t$  步 logits 为  $z_t \in \mathbb{R}^V$ ，概率  $p_{tj} = e^{z_{tj}} / \sum_k e^{z_{tk}}$ ，真实 token 索引  $y_t$ ，则

$$\ell_t = -z_{t,y_t} + \log \sum_k e^{z_{tk}}, \quad (6.3)$$

逐 logit 梯度

$$\frac{\partial \ell_t}{\partial z_{tj}} = p_{tj} - \mathbf{1}\{j = y_t\}. \quad (6.4)$$

Hessian 正是 softmax Jacobian

$$\nabla_z^2 \ell_t = \text{diag}(p_t) - p_t p_t^T \succeq 0. \quad (6.5)$$

所以交叉熵关于 logits 凸，但关于深网参数并不凸。

对非 padding token 集合  $\mathcal{I}$ ，平均损失和困惑度

$$\bar{L} = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \ell_t, \quad \text{PPL} = e^{\bar{L}}. \quad (6.6)$$

因此 PPL 是真实 token 概率倒数的几何平均：

$$\text{PPL} = \left( \prod_{t \in \mathcal{I}} \frac{1}{p_\theta(x_t | x_{<t})} \right)^{1/|\mathcal{I}|}. \quad (6.7)$$

不同 tokenizer 的 token 粒度不同，PPL 不能不经换算直接横向比较。

## 7 旋转位置编码的相对位置恒等式

对二维坐标对，定义旋转

$$R(m\omega) = \begin{bmatrix} \cos(m\omega) & -\sin(m\omega) \\ \sin(m\omega) & \cos(m\omega) \end{bmatrix}. \quad (7.1)$$

位置  $m, n$  的 query、key 分别为  $q_m = R(m\omega)q$ 、 $k_n = R(n\omega)k$ 。内积

$$q_m^T k_n = q^T R(m\omega)^T R(n\omega) k \quad (7.2)$$

$$= q^T R((n-m)\omega) k. \quad (7.3)$$

第二步用到  $R(a)^T = R(-a)$  和  $R(a)R(b) = R(a+b)$ 。所以绝对位置旋转后的内积只依赖相对距离  $n-m$ 。

在  $d_h$  维中对相邻坐标对使用频率

$$\omega_j = \theta^{-2j/d_h}, \quad j = 0, \dots, d_h/2 - 1. \quad (7.4)$$

低  $j$  频率高、分辨近距离，高  $j$  频率低、覆盖远距离。若推理长度远超训练长度，相位  $m\omega_j$  的外推和周期混叠会改变注意力几何；位置插值本质上是重新缩放这些相位。

## 8 RMSNorm 的 Jacobian

忽略可学习增益，RMSNorm

$$y = \frac{x}{s}, \quad s = \sqrt{\frac{1}{d} x^T x + \epsilon}. \quad (8.1)$$

微分

$$ds = \frac{x^T dx}{ds}, \quad (8.2)$$

因此

$$dy = \frac{1}{s} dx - \frac{x}{s^2} ds \quad (8.3)$$

$$= \left( \frac{1}{s} I - \frac{xx^T}{ds^3} \right) dx. \quad (8.4)$$

故

$$J_{\text{RMS}} = \frac{1}{s} I - \frac{xx^T}{ds^3}. \quad (8.5)$$

与 LayerNorm 相比，它没有去均值投影  $I - d^{-1}\mathbf{1}\mathbf{1}^T$ ，因此不消除常数方向。加上逐坐标增益  $g$  后，Jacobain 左乘  $\text{diag}(g)$ 。

谱上，对任意  $v \perp x$ ， $Jv = v/s$ ；沿  $x$  方向

$$Jx = \left( \frac{1}{s} - \frac{\|x\|^2}{ds^3} \right) x = \frac{\epsilon}{s^3} x. \quad (8.6)$$

当  $\epsilon$  很小，径向尺度方向被强烈压制，而切向方向按  $1/s$  缩放。

## 9 SwiGLU 前馈层的逐项梯度

SwiGLU 可写

$$a = xW_a, \quad b = xW_b, \quad h = \text{swish}(a) \odot b, \quad y = hW_o, \quad (9.1)$$

其中

$$\text{swish}(a) = a\sigma(a). \quad (9.2)$$

其导数

$$\frac{d}{da}[a\sigma(a)] = \sigma(a) + a\sigma(a)(1 - \sigma(a)). \quad (9.3)$$

令  $g_h = \partial\mathcal{L}/\partial h$ ，则

$$g_a = g_h \odot b \odot [\sigma(a) + a\sigma(a)(1 - \sigma(a))], \quad (9.4)$$

$$g_b = g_h \odot \text{swish}(a), \quad (9.5)$$

$$\nabla_{W_a}\mathcal{L} = x^T g_a, \quad \nabla_{W_b}\mathcal{L} = x^T g_b, \quad (9.6)$$

$$\nabla_x\mathcal{L} = g_a W_a^T + g_b W_b^T. \quad (9.7)$$

门分支  $b$  同时调制激活和  $a$  分支梯度，故两个投影不是可独立解释的普通 MLP。

## 10 MoE 路由与负载

对 token  $x_i$ ，router logits  $r_i = W_r x_i$ ，概率

$$p_{ie} = \frac{e^{r_{ie}}}{\sum_{j=1}^E e^{r_{ij}}}. \quad (10.1)$$

若 top- $k$  专家集合  $S_i$ ，归一化门

$$\tilde{p}_{ie} = \frac{p_{ie}\mathbf{1}\{e \in S_i\}}{\sum_{j \in S_i} p_{ij}}, \quad y_i = \sum_{e \in S_i} \tilde{p}_{ie} F_e(x_i). \quad (10.2)$$

固定集合  $S_i$  内可正常求导；集合边界的 arg-top- $k$  不连续，几乎处处把未选专家梯度置零。

令软重要性

$$P_e = \frac{1}{N} \sum_i p_{ie}, \quad (10.3)$$

硬负载

$$F_e = \frac{1}{N} \sum_i \mathbf{1}\{e \in S_i\}/k. \quad (10.4)$$

常见平衡项

$$L_{\text{bal}} = E \sum_e P_e F_e \quad (10.5)$$

在均匀  $P_e = F_e = 1/E$  时等于 1。把硬  $F_e$  停止梯度后，router 梯度只通过  $P_e$ ，会降低当前过载专家的概率；它是训练启发式，不等同于严格容量约束。

若每专家容量为

$$C_e = \left\lceil \frac{Nk}{E} c_{\text{cap}} \right\rceil, \quad (10.6)$$

超过容量的 token 必须丢弃或转送。即使平均负载均匀，局部批次方差仍可能溢出。

## 11 低秩 KV 潜变量的吸收

设 key/value 由共享潜变量

$$c_t = W_c x_t \in \mathbb{R}^{d_c}, \quad k_t = W_k c_t, \quad v_t = W_v c_t. \quad (11.1)$$

注意力 logit

$$q_s^T k_t = q_s^T W_k c_t = (W_k^T q_s)^T c_t. \quad (11.2)$$

因此解码时可把  $W_k$  吸收到 query 投影，缓存  $c_t$  而非完整  $k_t$ 。若 value 聚合

$$o_s = \sum_t p_{st} W_v c_t = W_v \left( \sum_t p_{st} c_t \right), \quad (11.3)$$

$W_v$  可放到加权求和之后。缓存从每 token 的  $d_k + d_v$  降为  $d_c$ ，前提是位置编码等操作不破坏这些线性交换关系；对只作用在部分 key 维度的 RoPE，需把旋转部分另行缓存或重构。

## 12 多 token 预测的联合似然

若同一隐藏状态  $h_t$  用  $K$  个头预测  $x_{t+1}, \dots, x_{t+K}$ ,

$$\mathcal{L}_t = \sum_{k=1}^K \lambda_k [-\log p_{\theta,k}(x_{t+k} | h_t)]. \quad (12.1)$$

共享骨干梯度

$$\nabla_{h_t} \mathcal{L}_t = \sum_{k=1}^K \lambda_k g_{t,k}. \quad (12.2)$$

其平方范数精确展开

$$\left\| \sum_k \lambda_k g_{t,k} \right\|^2 = \sum_k \lambda_k^2 \|g_{t,k}\|^2 + 2 \sum_{j < k} \lambda_j \lambda_k g_{t,j}^T g_{t,k}. \quad (12.3)$$

交叉内积为负时存在任务冲突；辅助头退火相当于训练后期逐渐去掉这些交叉项，使最终目标回到下一 token 似然。

## 13 可分离幂律与计算约束下的最优分配

设验证损失模型

$$L(N, D) = L_\infty + AN^{-\alpha} + BD^{-\beta}, \quad A, B, \alpha, \beta > 0, \quad (13.1)$$

其中  $N$  是模型规模代理量、 $D$  是训练 token 数。训练计算近似

$$C = \kappa ND. \quad (13.2)$$

固定  $C$  时  $D = C/(\kappa N)$ , 代入可约为一元函数

$$\tilde{L}(N) = L_\infty + AN^{-\alpha} + B \left( \frac{\kappa N}{C} \right)^\beta. \quad (13.3)$$

一阶条件

$$-\alpha AN^{-\alpha-1} + \beta B \left( \frac{\kappa}{C} \right)^\beta N^{\beta-1} = 0. \quad (13.4)$$

整理得

$$N^{\alpha+\beta} = \frac{\alpha A}{\beta B} \left( \frac{C}{\kappa} \right)^\beta. \quad (13.5)$$

因此

$$N^*(C) = \left( \frac{\alpha A}{\beta B} \right)^{1/(\alpha+\beta)} \left( \frac{C}{\kappa} \right)^{\beta/(\alpha+\beta)}, \quad (13.6)$$

$$D^*(C) = \left( \frac{\beta B}{\alpha A} \right)^{1/(\alpha+\beta)} \left( \frac{C}{\kappa} \right)^{\alpha/(\alpha+\beta)}. \quad (13.7)$$

两个最优指数相加为 1, 保证  $N^*D^* \propto C$ 。

在最优点, 一阶条件还给出两项的比例

$$\alpha A(N^*)^{-\alpha} = \beta B(D^*)^{-\beta}. \quad (13.8)$$

不是两项数值相等, 而是乘上各自幂指数后相等。

## 14 最优损失随计算的幂指数

将  $N^*, D^*$  代入, 两项都按

$$C^{-\frac{\alpha\beta}{\alpha+\beta}} \quad (14.1)$$

衰减。因此

$$L^*(C) = L_\infty + KC^{-\gamma}, \quad \gamma = \frac{\alpha\beta}{\alpha+\beta}, \quad (14.2)$$

常数  $K$  由  $A, B, \alpha, \beta, \kappa$  决定。若任一资源的幂指数很小, 它将成为调和式组合中的瓶颈。

边际计算收益

$$\frac{dL^*}{dC} = -\gamma KC^{-\gamma-1} \quad (14.3)$$

随规模快速减小; 幂律外推给的是平均趋势, 不保证单次训练的确定回报。

## 15 对数线性拟合与不可忽略的 $L_\infty$

若只拟合单项  $y = Ax^{-\alpha}$ , 取对数得到

$$\log y = \log A - \alpha \log x, \quad (15.1)$$

可以线性回归。但实际有不可约项

$$L(x) = L_\infty + Ax^{-\alpha}, \quad (15.2)$$

则

$$\log L \neq \log A - \alpha \log x. \quad (15.3)$$

只有对  $L - L_\infty$  取对数才线性, 而  $L_\infty$  本身未知, 需要非线性联合拟合。

若误设  $\tilde{L}_\infty = L_\infty + \delta$ , 变换量变为

$$\log(L - \tilde{L}_\infty) = \log(Ax^{-\alpha} - \delta). \quad (15.4)$$

在大规模、幂律项较小时, 对  $\delta$  极敏感; 这解释了外推指数和渐近损失之间的强相关。



## 16 参数估计的不确定性传播

令拟合参数  $\psi = (\log A, \log B, \alpha, \beta, L_\infty)$ , 最小二乘目标

$$S(\psi) = \sum_i w_i [L_i - L(N_i, D_i; \psi)]^2. \quad (16.1)$$

在最优点  $\hat{\psi}$  附近二阶近似

$$S(\psi) \approx S(\hat{\psi}) + \frac{1}{2}(\psi - \hat{\psi})^T H(\psi - \hat{\psi}). \quad (16.2)$$

若残差近似高斯, 参数协方差可估为

$$\text{Cov}(\hat{\psi}) \approx \hat{\sigma}^2 H^{-1}. \quad (16.3)$$

对由参数导出的最优规模  $g(\psi) = \log N^*(C)$ , delta 方法给出

$$\text{Var}(g(\hat{\psi})) \approx \nabla_\psi g^T \text{Cov}(\hat{\psi}) \nabla_\psi g. \quad (16.4)$$

因此只报告单条最优曲线会隐藏幂指数拟合误差经外推放大的区间。

## 17 模型规模代理量的选择

稠密 Transformer 每 token 前向 FLOPs 常近似与参数量成正比, 训练再乘常数, 于是  $C \approx \kappa ND$ 。MoE 中总参数  $N_{\text{total}}$  与每 token 激活参数  $N_{\text{active}}$  不同:

$$C \approx \kappa N_{\text{active}} D, \quad (17.1)$$

而容量和存储更接近  $N_{\text{total}}$ 。若把总参数直接代入稠密计算公式, 会高估训练计算。

假设每层有  $E$  个专家、每 token 激活  $k$  个, 专家参数总量  $N_e$ , 则粗略

$$N_{\text{active}} = N_{\text{shared}} + \frac{k}{E} N_e, \quad N_{\text{total}} = N_{\text{shared}} + N_e. \quad (17.2)$$

路由不均衡还会让实际设备时间由最拥挤专家决定, 因此 FLOPs 相同也不保证墙钟时间相同。

## 18 两阶段或多阶段训练的计算核算

若不同阶段模型规模、序列长度或激活稀疏度不同, 总计算应相加

$$C_{\text{total}} = \sum_{j=1}^J \kappa_j N_{\text{active},j} D_j. \quad (18.1)$$

把全部 token 简单相加再乘最终模型规模只有在各阶段  $\kappa_j N_j$  相同才成立。这对继续预训练、长上下文阶段和多 token 预测辅助头尤其重要。

## 19 MLA 的低秩 KV 潜变量

标准多头注意力缓存每个 token 的  $K, V \in \mathbb{R}^{H \times d_h}$ 。MLA 先压缩

$$c_t^{KV} = W^{DKV} h_t \in \mathbb{R}^{d_c}, \quad (19.1)$$

再按头上投影

$$k_{t,h}^C = W_h^{UK} c_t^{KV}, \quad v_{t,h} = W_h^{UV} c_t^{KV}. \quad (19.2)$$

缓存从每 token 约  $2Hd_h$  个数降为  $d_c$  加少量位置键。该分解把 KV 映射秩限制在  $d_c$ 。

## 20 吸收矩阵与解码

查询内容部分  $q_h^C = W_h^{UQ} c_t^Q$  与键的点积

$$(q_h^C)^T k_{j,h}^C = (c_t^Q)^T (W_h^{UQ})^T W_h^{UK} c_j^{KV}. \quad (20.1)$$

可预先吸收中间矩阵，避免显式恢复完整键。位置部分单独使用 RoPE，从而不破坏可吸收的低秩内容通道。

## 21 细粒度 MoE

若  $N_r$  个共享专家始终激活、从  $N_s$  个路由专家选 top- $K$ ，输出

$$y = \sum_{i \in \mathcal{S}_{\text{shared}}} E_i(x) + \sum_{i \in \text{TopK}(g(x))} p_i E_i(x). \quad (21.1)$$

每 token 计算仅与  $N_r + K$  成正比，而参数容量随  $N_r + N_s$  增长。负载均衡损失用于防止路由塌缩，但会与任务最优路由产生权衡。

## 22 无辅助损失的偏置平衡

路由选择使用校正分数  $s_i + b_i$ ，但混合权重仍由原始  $s_i$  计算。若专家  $i$  负载超过目标，更新

$$b_i \leftarrow b_i - \eta; \text{quad 负载不足时 } b_i \leftarrow b_i + \eta. \quad (22.1)$$

偏置不经任务梯度且不进入专家输出数值，只改变 top- $K$  集合。因此它类似离散约束的对偶变量更新，可减少显式平衡损失对主目标的干扰。

## 23 多 token 预测

除下一 token 外，同时预测未来  $D$  个 token：

$$\mathcal{L}_{\text{MTP}} = \frac{1}{D} \sum_{k=1}^D [-\log p_{\theta}(x_{t+k} \mid x_{\leq t}, \text{前缀表示})]. \quad (23.1)$$

辅助头让当前表示包含更远未来信息。若权重过大，模型可能牺牲精确的一步条件分布；所以总目标采用主 NTP 损失加衰减的 MTP 权重。