

1

研究问题

单向上下文限制理解

- 从左到右预训练使每层无法同时利用左右两侧语境。
- 对问答等 token 级任务尤其不利，因为正确表示必须看到后文。
- 特征式迁移又依赖大量任务专属架构；BERT 追求统一的微调范式。

2

模型表征

单一双向编码器

- BERTBASE：12 层、768 隐藏维、12 头、1.1 亿参数；BERTLARGE：24/1024/16、3.4 亿参数。
- 输入由 WordPiece 词元、句段与位置嵌入相加；[CLS] 汇总序列，[SEP] 分隔文本对。
- 双向自注意力联合编码句对，替代先独立编码再做交叉注意力的流程。

3

预训练任务

MLM + NSP

- 随机选择 15% WordPiece，并依据完整上下文预测其原词。
- 其中 80% 替换为 [MASK]、10% 换成随机词、10% 保持不变，以缓解预训练/微调不一致。
- 下一句预测以 50/50 混合真实后句与随机句，学习文本对关系。

BERT

BERT

深度双向 Transformer 预训练

面向语言理解的预训练与微调 | 2019

先在无标注文本上预训练一个深度双向 Transformer 编码器，再通过极少的任务专属输出层与端到端微调，把同一表征迁移到多种语言理解任务。

掩码语言模型

双向编码

迁移学习

4

迁移方式

一次预训练、全面微调

- 预训练语料为 BooksCorpus 8 亿词与英文 Wikipedia 25 亿词。
- 分类任务在 [CLS] 上接 softmax；问答或序列标注直接使用逐 token 向量。
- 所有预训练参数端到端微调，通常只增加一个输出层，任务计算成本较低。

5

实验结果

11 项任务刷新 SOTA

- BERTLARGE 的官方 GLUE 为 80.5，MultiNLI 为 86.7%，较此前提升 7.7 与 4.6 个点。
- SQuAD v1.1 测试 F1 达 93.2，SQuAD v2.0 达 83.1。
- 消融表明深度双向性与 NSP 都有帮助；模型变大也能提升小数据下游任务。

6

意义与局限

通用语言表征范式

- BERT 把“预训练后微调”变成简单默认方案，显著减少手工任务架构。
- MLM 每步只监督少量 token 且存在 [MASK] 偏差；NSP 的价值也被后续研究重新检验。
- 每个任务仍需保存完整微调权重，由此推动 LoRA 等参数高效方法。