

1

研究问题

完整微调难以扩展

- 每个完整微调任务都复制全部预训练权重与优化器状态；GPT-3 175B 规模下几乎不可承受。
- Adapter 增加顺序层与推理延迟，提示微调又占用上下文且较难优化。
- 核心假设：下游适配的权重变化具有远低于原稠密矩阵的内在秩。

2

核心方法

分解权重增量

- $W = W_0 + \Delta W$; $\Delta W = BA$; $h = W_0x + BAx$
- 冻结 W_0 ，只训练 A 与 B ，秩 r 远小于原矩阵的 d 、 k 。
- A 用高斯初始化、 B 初始化为零，并用 α/r 缩放，使训练起点严格等于基础模型。

3

注入位置

适配注意力投影

- LoRA 可用于任意稠密层；论文重点研究 Transformer 的 Q/K/V/O 投影。
- 固定参数预算下，以小秩同时适配 W_q 与 W_v ，通常优于只给一个矩阵更大秩。
- GPT-3 隐藏维度 12,288，但秩仅 1-4 在多项任务已具竞争力。

LORA 低秩适配

LoRA

大语言模型的低秩适配

Low-Rank Adaptation of Large Language Models | 2021

冻结预训练模型，把每个任务的权重变化表示为极小低秩因子，在保持质量的同时大幅降低优化器内存、检查点体积与部署负担。

参数高效微调

低秩更新

零推理开销

4

系统收益

共享底座、轻量模块

- 只保存一个冻结基础模型与多个小型任务 LoRA，通过替换 A/B 快速切换任务。
- 部署时把 BA 合并进 W_0 ，相对原模型不增加任何推理延迟。
- GPT-3 175B 设置中，训练内存约从 1.2 TB 降至 350 GB，检查点从 350 GB 降至 35 MB。

5

实验结果

匹配或超过完整微调

- 在 RoBERTa、DeBERTa、GPT-2 与 GPT-3 上，以极少参数匹配或超过完整微调。
- GPT-3 仅用 470 万 LoRA 参数，在 WikiSQL、MultiNLI 与 SAMSum 上保持强性能。
- 相对 GPT-3 的 Adam 完整微调：训练参数约少 1 万倍、GPU 内存低 3 倍、吞吐更高。

6

意义与局限

适配本质具有低秩结构

- 学到的增量会放大原预训练权重主奇异子空间之外的任务专属方向。
- 最佳秩与目标矩阵依赖任务和模型，论文未建立统一扩展规律。
- LoRA 只减少可训练状态，不压缩冻结底座；QLoRA 进一步解决这一主要内存成本。