

1

研究问题

冻结底座仍占绝大内存

- LoRA 减少可训练状态，但 16 位 65B 底座和激活仍使微调难以普及。
- 常规 16 位 LLaMA-65B 微调需要超过 780 GB GPU 内存。
- 目标是用 4 位存储冻结模型、只训练适配器，同时保持 16 位质量。

2

QLoRA 路径

4 位存储、16 位计算

- 预训练权重以 4 位 NF4 存储，矩阵乘时才按块解量化为 bfloat16。
- 梯度穿过冻结量化权重，流向 bfloat16 LoRA 因子；底座本身不更新。
- 底座才是内存主体，因此可覆盖更多 LoRA 层而几乎不增加总占用。

3

三项创新

NF4 + 双重量化 + 分页

- NF4 按零均值正态分布设计等概率区间，匹配预训练权重统计特性。
- 双重量化继续压缩分块缩放常数，节省约 0.373 bit/参数；65B 约省 3 GB。
- 分页优化器利用 CPU/GPU 统一内存吸收梯度检查点峰值，避免 OOM。

QLoRA 量化微调

QLoRA

量化大模型的高效微调

Efficient Finetuning of Quantized LLMs | 2023

让梯度穿过冻结的 4 位量化语言模型，只更新 LoRA 适配器，从而用单张 48 GB GPU 微调 65B 模型，并恢复 16 位适配性能。

4 位训练

NF4

LoRA

4

研究设计

规模、数据与评测

- 1000 多次实验覆盖 8000 万至 650 亿参数、多种架构、指令数据集与量化类型。
- NF4 + 双重量化在 7B-65B 的 MMLU 上匹配 bfloat16 LoRA，并优于 FP4。
- 结合人工、GPT-4 与基准评测，揭示成绩高度依赖训练数据与评测的相似度。

5

实验结果

单卡训练 GUANACO

- 65B 微调从常规 16 位的 780 GB 以上降至单张 48 GB GPU。
- Guanaco-65B 用 24 小时达到 ChatGPT 的 99.3%；33B 在 24 GB 上不足 12 小时达到 97.8%。
- 7B 部署仅约 5 GB，在论文 Vicuna 评测中达到 ChatGPT 的 87.0%。

6

局限与影响

普及能力也需谨慎

- 因成本限制，33B/65B 未验证与完整 16 位微调等价，只验证了与 16 位 LoRA 等价。
- 聊天基准狭窄且受数据影响；责任 AI、其他位宽与适配器评估仍有限。
- QLoRA 降低研究与隐私应用门槛，但廉价定制同样具有双重用途风险。