

1

研究问题

流畅文本缺乏证据

- 语言模型知道该说什么、如何表达，却常生成无来源支持的事实声明。
- 即使采用检索增强，模型仍可能忽略、超出或直接违背检索文档。
- “为归因而编辑”需同时最大化证据支持并保留原意、风格与结构。

4

评价体系

归因 x 保留

- AIS 判断每句话是否被至少一个已识别来源完全支持；auto-AIS 使用 NLI 自动近似。
- 保留度结合人工原意相似度与字符级 Levenshtein 相似度。
- 调和均值 F1AP 显式体现权衡：删除或重写全部内容虽易归因，却会毁掉原文。

2

研究阶段

把每个声明变成问题

- PaLM 用 6 个示例生成全面核验问题，并取 3 次采样的并集扩大覆盖。
- 每个查询通过网络搜索 5 个页面，再用四句滑窗切出候选证据片段。
- 相关性模型筛选证据，最终选择最多 5 条、最大化问题覆盖的归因报告。

RARR 研究与修订

RARR

研究并修订语言模型输出

Researching and Revising What Language Models Say | 2023

为任意生成文本后装证据归因：逐项研究其声明，只在文本与证据冲突时修改，并同时返回最小改动后的文章与精简来源报告。

证据归因

网络检索

后编辑

5

实验结果

与生成模型无关的提升

- PaLM 的 NQ 文本中，人工 AIS 从 35.4 升至 43.4，综合保留 83.1，F1AP 达 57.0。
- StrategyQA 推理链 AIS 从 24.5 升至 31.5、保留 84.6；QReCC 从 13.2 升至 28.3、保留 78.1。
- 比 EFEC 或 LaMDA Research 更能保留风格结构，并可提升 NQ 下游答案准确率。

3

修订阶段

只修改不一致之处

- 一致性模型围绕每个问题比较当前文本与证据，并显式推断两者答案。
- 若存在冲突，编辑模型定位有问题的片段，以最小改动使其符合证据。
- 迭代应用编辑；字符距离过大的修改会被拒绝，以控制无关漂移。

6

局限与风险

有来源不等于真实

- 搜索可能返回低质、冲突或有偏来源；RARR 只验证“是否有支持”，不判断来源可信度。
- 诗歌、长文档、逻辑连贯性及“哪些声明需要引用”仍很困难。
- 少样本大模型调用与网络研究成本高；部分归因的输出必须明确标注。