

1

研究问题

大规模不可解后验

- 含连续潜变量的有向生成模型常具有不可计算的边缘似然与真实后验。
- 逐样本 MCMC 或迭代变分更新成本过高，不适合大数据与小批量训练。

2

概率自编码器

编码的是分布

- 识别模型 $q_{\phi}(z|x)$ 摊销后验推断；解码器 $p_{\theta}(x|z)$ 定义生成似然。
- 标准高斯先验约束连续潜码，可用于采样、去噪与低维可视化。

3

学习目标

最大化 ELBO

- $ELBO = E_q[\log p_{\theta}(x|z)] - KL(q_{\phi}(z|x) || p(z))$
- 重构项负责解释数据，KL 项把每个近似后验正则到先验附近。

VAE

Auto-Encoding Variational Bayes

变分自编码学习

Kingma 与 Welling | arXiv:1312.6114v11

把摊销式变分推断与可微采样路径结合，将难以求解的潜变量学习转化为可端到端优化的随机梯度问题。

变分推断

潜变量

重参数化

4

关键技巧

把随机性移到外部

- $z = \mu_{\phi}(x) + \sigma_{\phi}(x) * \epsilon; \epsilon \sim N(0, I)$
- 重参数化得到低方差、可微的蒙特卡洛估计器，可直接用普通随机梯度优化。

5

实验证据

MNIST 与 FREY FACES

- 在不同潜空间维度下，AEVB 比 wake-sleep 收敛更快并达到更优变分下界。
- 实验学习平滑二维流形并生成样本；小批量时每个数据点约一次采样即可训练。

6

意义与局限

生成学习通用模板

- 论文打通概率推断与神经自编码器，奠定现代 VAE 的训练范式。
- 原始估计器偏向可重参数化的连续潜变量；简单高斯解码器可能产生模糊样本与较松下界。