

1

研究问题

摆脱固定标签集合

- 监督视觉只能学习预定类别，每增加一个概念都需要新的标注样本。
- 互联网图文对提供广泛监督，但学习任务必须能扩展到噪声自然语言。

2

数据与编码器

4 亿网络图文对

- 用 4 亿图像-文本对从头训练图像编码器（ResNet 或 ViT）与 Transformer 文本编码器。
- 两类编码器把输入映射到共享归一化嵌入空间；推理时可缓存文本原型。

3

训练目标

找出正确描述

- 一个批次内计算全部 $N \times N$ 图文余弦相似度，并用可学习温度缩放 logits。
- 对称交叉熵同时预测每张图对应的描述，以及每段描述对应的图像。

CLIP

Learning Transferable Visual Models

可迁移视觉模型

Radford 等 | arXiv:2103.00020v1

通过识别匹配的网络图文对来预训练图像与文本编码器，再把自然语言类别描述直接变成零样本视觉分类器。

对比学习

图文对齐

零样本迁移

4

零样本迁移

类别名变成提示词

- 把类别名嵌入“a photo of a {label}”等自然语言模板。
- 提示集成与数据集相关措辞无需更新权重即可提升稳健性。

5

实验证据

覆盖 30 多个数据集

- CLIP 迁移到 OCR、动作、地理定位与细粒度识别；ImageNet 零样本性能匹配原始监督 ResNet-50。
- 最大模型常可竞争任务专属基线，并在多种自然分布偏移上更稳健。

6

意义与局限

用语言操作视觉概念

- CLIP 推动开放词表识别，并成为多模态生成与检索常用的语义骨干。
- 网络数据会带入社会偏差；计数、细粒度区分与抽象任务仍弱，结果也受提示词影响。