

1

研究问题

视觉掩码学习有其特殊性

- 图像空间冗余很强，低掩码率会让重构过于简单，并把算力浪费在可见内容上。
- 视觉 Transformer 需要一种能平滑扩展到超大模型的自监督目标。

2

非对称设计

只编码可见图像块

- 随机移除约 75% 图像块；重型 ViT 编码器只接收剩余 25%，且不输入 mask token。
- 小型解码器插入可学习 mask token 并恢复全部图像块；预训练后将其丢弃。

3

训练目标

恢复缺失像素

- 目标是掩码图像块的归一化像素值，使用均方误差优化。
- 高掩码率迫使模型理解整体结构，而非复制邻近纹理，同时保留简单学习信号。

MAE

Masked Autoencoders

掩码自编码视觉预训练

He 等 | arXiv:2111.06377v3

遮住大部分图像块，只编码少量可见块，再用轻量解码器恢复缺失像素，实现可扩展的 ViT 自监督预训练。

掩码建模

非对称编码器

自监督学习

4

效率与扩展

更少词元、更大模型

- 只编码四分之一图像块，显著降低二次注意力开销，训练速度提高至少 3 倍。
- 同一方案从 ViT-Base 扩展到 ViT-Huge，不需要对比负样本或教师网络。

5

实验证据

仅用 IMAGENET-1K 达 87.8%

- 微调 ViT-Huge 达到 ImageNet-1K 87.8% top-1，是当时只用该数据集方法中的最佳结果。
- 预训练强力迁移到 COCO 检测与 ADE20K 分割，并超过监督预训练。

6

意义与局限

可扩展视觉预训练

- MAE 证明稀疏输入与高掩码率可以把普通重构变成强表征学习器。
- 像素恢复并不显式追求语义；超大规模预训练仍消耗大量算力，且原论文聚焦静态图像。