

1

研究问题

由高维原始输入直接控制

- 传统强化学习依赖手工状态特征，也难以让非线性函数逼近适应相关的在线数据。
- 目标是用同一架构在视觉差异很大的 Atari 游戏中从像素映射到动作。

2

状态与网络

从像素到动作价值

- 画面缩放为 84x84 灰度图，并叠加连续 4 帧以表达运动。
- 卷积网络为每个合法摇杆动作输出 Q 值；epsilon-greedy 策略负责探索。

3

学习规则

时序差分控制

- $y = r + \gamma \max_a Q(s_{next}, a)$; $loss = (y - Q(s, a))^2$
- 通过裁剪奖励和 Q 学习目标反向传播，联合学习视觉特征与动作价值。

DQN

Playing Atari with Deep RL

用深度强化学习玩 Atari

Mnih 等 | arXiv:1312.5602v1

把卷积视觉、Q 学习与经验回放结合，在一个端到端智能体中直接从游戏像素学习动作价值。

Q 学习

经验回放

Atari 像素

4

经验回放

打破时间相关性

- 每个转移存入回放缓冲区，再随机抽取小批量复用历史经验并混合多个时期的策略。
- 回放提高数据利用率，也让神经网络看到的非平稳数据流更平滑。

5

实验证据

7 个 ATARI 2600 游戏

- 同一架构与超参数只接收像素、奖励和终止信号，不使用游戏专属特征。
- 在 7 个游戏中的 6 个超过此前强化学习方法，并在 3 个游戏中超过人类专家。

6

意义与局限

深度表征进入强化学习

- DQN 奠定从原始感知输入端到端学习控制的深度强化学习范式。
- 早期实验游戏数量少、消耗大量帧，且自举目标与变化数据可能导致不稳定。