

1

研究问题

不靠复杂 TRPO 也能稳定更新

- 普通策略梯度可能迈出破坏性大步；TRPO 虽能控制更新，却依赖二阶约束优化。
- 标准在线方法还常在一次梯度更新后丢弃样本。

4

训练循环

采样、优势、多轮优化

- 多个 actor 收集轨迹；广义优势估计支持对同一数据进行多轮打乱小批量更新。
- 联合目标还加入价值函数误差与熵奖励。

2

概率比

比较新旧策略

- $r_t(\theta) = \pi_\theta(a_t|s_t) / \pi_{old}(a_t|s_t)$
- 该比值衡量更新后策略对行为策略所采样动作的概率改变了多少。

5

实验证据

MUJOCO 与 49 个 ATARI 游戏

- PPO 在模拟运动控制与 Atari 上测试，整体超过其他在线策略梯度方法。
- 它在样本复杂度、实现简洁度与墙钟时间之间取得良好经验平衡。

3

裁剪代理目标

移除过度更新的收益

- $L_{clip} = E[\min(r_t * A_t, clip(r_t, 1-eps, 1+eps) * A_t)]$
- 当 r_t 离开邻域时，裁剪以悲观方式限制收益，同时仍可使用简单一阶优化。

6

意义与局限

实用默认算法

- PPO 让类似信赖域的策略更新更易实现，并成为包括语言模型对齐在内的常用基线。
- 它仍是在线且耗数据；裁剪不构成正式信赖域保证，性能也依赖超参数。

PPO

Proximal Policy Optimization
近端策略优化

Schulman 等 | arXiv:1707.06347v2

在多个小批量轮次中复用在线轨迹，并裁剪新旧策略概率比，在无需 TRPO 约束优化器的情况下控制更新幅度。

策略梯度 裁剪目标 演员-评论家