

1

研究问题

样本成本与脆弱收敛

- 无模型连续控制常需大量交互，并对超参数和随机种子高度敏感。
- 在线方法稳定但丢弃数据；确定性离线 actor 又可能探索不足。

4

离线策略循环

重复利用经验

- 行为策略把转移写入回放池；每次环境步可支持多次梯度更新且无需重要性采样。
- 目标平滑与双 Q 变体降低自举误差并稳定学习。

2

最大熵目标

同时追求奖励与随机性

- $J(\pi) = E[\sum_t r(s_t, a_t) + \alpha * H(\pi(.|s_t))]$
- 熵奖励多样行为，改善探索，并允许策略保留多个近似最优模式。

5

实验证据

连续控制基准

- 在 MuJoCo 运动任务上，SAC 达到当时最佳回报，并比在线与离线基线更省样本。
- 不同随机种子表现相近，改善深度强化学习的重要可复现性问题。

3

演员-评论家

软价值学习

- 从回放转移训练可重参数化随机策略、软 Q 函数与价值网络。
- 软 Bellman 备份计入未来熵；actor 则逼近由 Q 指数化得到的动作分布。

6

意义与局限

把熵变成控制原则

- SAC 使最大熵强化学习成为稳健、样本高效连续控制的实用默认方案。
- 原始方法仍需选择奖励尺度或温度，假设连续动作，并继承离线策略近似偏差。

SAC

Soft Actor-Critic
软演员-评论家

Haarnoja 等 | arXiv:1801.01290v2

把离线策略经验回放与同时最大化奖励和熵的随机 actor 结合，实现高效探索与稳定连续控制。

最大熵 离线策略 连续控制