

1

总体目标

通用多模态能力

- 系统接收图像与文本混合输入并生成文本，同时提升相对早期 GPT 的可靠性。
- 评测覆盖职业考试、学术基准、多语言迁移与安全行为。

4

学术证据

多项考试达到人类水平

- 模拟律师考试约位于前 10%，而 GPT-3.5 约位于后 10%。
- 五样本 MMLU 达 86.4%，且无需考试专属训练即可在多种标准化考试上取得强结果。

2

模型与训练

TRANSFORMER 与后训练

- GPT-4 先做下一 token 预测预训练，再通过人类反馈强化学习进行对齐。
- 报告有意不披露架构规模、硬件、训练算力与数据组成。

5

多模态与对齐

图像、语言与事实性

- 视觉输入支持图表、文档与场景推理；多项基准被翻译到 26 种语言测试。
- 后训练改善事实性、拒答与指令遵循，并结合红队测试与专家反馈。

3

可预测扩展

完整训练前先预测

- 基础设施与优化方法被设计为跨规模保持一致行为。
- 算力不超过 GPT-4 千分之一的小模型即可预测最终损失与部分 HumanEval 通过率。

6

局限与透明度

能力强但仍不可靠

- GPT-4 仍会幻觉、推理出错，知识截止固定，也不会从部署经验持续学习。
- 有限技术披露阻碍独立复现，也让关键能力与安全机制保持不透明。

GPT-4

GPT-4 Technical Report
GPT-4 技术报告

OpenAI | arXiv:2303.08774v6

把可预测的下一词预训练与对齐后训练扩展为多模态模型，在职业考试、学术基准与视觉语言任务上表现强劲。

多模态

可预测扩展

对齐