

1

研究问题

上下文成为瓶颈

- 真实任务常包含长文档集合、数小时媒体，以及相隔数百万 token 的细节。
- 短窗口迫使系统依赖检索流水线，也阻碍模型联合推理全部证据。

2

模型家族

PRO 与 FLASH

- Gemini 1.5 采用源自 Gemini 1.0 的高算效多模态混合专家架构。
- Pro 优先追求能力；Flash 更轻、更适合服务，质量仅小幅下降。

3

长多模态上下文

文档、视频与音频

- 模型可在一个上下文中接收长文本、代码仓库、多张图像、数小时视频与音频。
- 标准百万 token 窗口还被压力测试到至少 1000 万 token。

GEMINI 1.5

Gemini 1.5：百万级上下文

Gemini 团队 | arXiv:2403.05530v5

把高算效多模态模型扩展到数百万 token，使其能跨长文档、视频与音频回忆细节并联合推理。

超长上下文

多模态 MoE

Pro 与 Flash

4

回忆与学习

1000 万 TOKEN 仍超过 99%

- 跨模态“大海捞针”检索接近完美，在至少 1000 万 token 内仍超过 99%。
- 只给一份语法手册，模型即可在上下文学习翻译低资源语言 Kalamang。

5

实验证据

长输入任务达到 SOTA

- Gemini 1.5 推进长文档问答、长视频问答与长上下文语音识别，并广泛匹配或超过 Gemini 1.0 Ultra。
- 与专业人士合作的 10 类工作任务报告节省 26% 至 75% 时间。

6

意义与局限

把上下文变成工作记忆

- 超长上下文成为多模态检索、分析与快速上下文适配的统一工作区。
- 针式召回比深度综合简单；极长提示增加延迟、成本和隐私风险，系统细节也未完全公开。