

1

研究问题

以更低成本获得前沿质量

- 稠密扩展会抬高训练、激活计算与内存带宽；长上下文解码还被 KV cache 流量主导。
- 目标是构建训练和推理都经济的强开源模型。

2

规模与数据

2360 亿总参数、210 亿激活

- DeepSeek-V2 是 2360 亿总参数的混合专家模型，每个 token 只激活 210 亿。
- 在 8.1 万亿高质量多语言与代码 token 上预训练，并扩展到 128K 上下文。

3

MLA

压缩 KV CACHE

- 多头潜在注意力先把键和值投影到跨头共享的紧凑潜向量，再按需重构。
- 在保留多头表达力的同时，大幅减少每 token 缓存存储与内存读取。

DEEPSEEK-V2

DeepSeek-V2

高效混合专家语言模型

DeepSeek-AI | arXiv:2405.04434v5

将稀疏专家与压缩潜在注意力结合，使 2360 亿参数模型每个 token 只激活 210 亿，并高效服务 128K 上下文。

MLA

DeepSeekMoE

高效推理

4

DeepSeekMoE

细粒度稀疏专家

- 把专家切成更小单元，使每个 token 能灵活组合多种专家。
- 共享专家学习公共知识，路由专家负责专门化；辅助均衡避免路由坍塌。

5

效率证据

更低成本、更高吞吐

- 相对 DeepSeek 67B，训练成本下降 42.5%，KV cache 减少 93.3%，最大生成吞吐提高 5.76 倍。
- 经 SFT 与强化学习后，基础版和对话版达到开源模型第一梯队。

6

意义与局限

模型与服务协同设计

- DeepSeek-V2 证明注意力内存与稀疏激活需要联合优化，而不能只关注参数量。
- 完整模型存储与路由仍很大；分布式 MoE 复杂度、数据透明度与安全评测仍是问题。