

1

总体目标

不付出稠密成本也能扩展质量

- 前沿语言模型需要巨大算力，稀疏路由还可能不稳定并造成昂贵通信。
- DeepSeek-V3 追求以更低成本训练、达到闭源强模型水平的开放 MoE。

2

模型规模

6710 亿总参数、370 亿激活

- 模型共 6710 亿参数，每 token 激活 370 亿，沿用 DeepSeekMoE 与多头潜在注意力。
- 先在 14.8 万亿高质量多样 token 上预训练，再做监督微调与强化学习。

3

路由创新

无需辅助均衡损失

- 基于偏置的专家负载均衡动态调整路由，不再加入可能损伤性能的辅助损失。
- 仅保留很小的序列级均衡项处理极端情况，同时维持专家专门化。

DEEPSEEK-V3

DeepSeek-V3 技术报告

DeepSeek-AI | arXiv:2412.19437v2

把高效 MLA-MoE 扩展到 6710 亿参数，并改进路由、token 预测与低精度系统，实现稳定且经济的前沿训练。

6710 亿 MoE

无辅助损失路由

FP8 与 MTP

4

训练系统

MTP、FP8 与 DUALPIPE

- 多 token 预测让每个位置同时预测更多未来 token，增加监督并支持推测解码。
- FP8 混合精度与 DualPipe 流水调度降低内存、通信气泡和总体成本。

5

实验证据

278.8 万 H800 GPU 小时

- 完整训练消耗 278.8 万 H800 GPU 小时；报告称没有不可恢复损失尖峰，也未回滚。
- 广泛评测中 DeepSeek-V3 超过其他开放模型，并可比多个领先闭源模型。

6

意义与局限

算法与系统协同设计

- V3 证明稀疏架构、路由目标、预测任务与硬件调度可共同释放规模收益。
- 训练仍需大型基础设施；污染、数据治理、MoE 服务复杂度与安全需要独立研究。