

1

研究问题

不依赖人类推理轨迹

- 强推理模型常依赖大量由人类或更强模型制作的监督思维链示范。
- 核心问题是：仅用正确答案奖励，能否让高级推理模式自行涌现？

4

推理蒸馏

把能力迁移到小模型

- 使用 DeepSeek-R1 输出微调 15 亿到 700 亿参数的 Qwen 与 Llama 稠密模型。
- 对小基础模型而言，蒸馏效果优于直接照搬同等规模强化学习。

2

R1-Zero

从基础模型直接做纯 RL

- 组相对策略优化比较同组采样回答，因此无需单独价值模型。
- 准确性与格式奖励诱导更长推理、自我验证、反思，以及论文观察到的“顿悟”转变。

5

实验证据

数学、代码与 STEM

- DeepSeek-R1 在 AIME 2024 达 79.8% pass@1、MATH-500 达 97.3%，Codeforces 评级 2029。
- 蒸馏 32B 模型在论文报告的多项推理基准上超过 OpenAI o1-mini。

3

R1 流程

冷启动与两阶段 RL

- 先用少量精选长思维链改善可读性，再在数学、代码与逻辑上做推理强化学习。
- 拒绝采样推理数据与通用数据支持 SFT，随后用 RL 同时优化帮助性、安全性与推理。

6

意义与局限

把测试时思考学成策略

- 结果奖励 RL 可在无标注推理路径时诱导自适应策略，并把能力传给小模型。
- 长轨迹提高推理成本；奖励投机、语言混杂、忠实性、基准集中与安全仍未解决。

DEEPSEEK-R1

通过强化学习激发推理能力

DeepSeek-AI | arXiv:2501.12948v2

用可验证结果上的强化学习激发长程推理，再结合冷启动数据、广泛对齐与蒸馏，得到实用推理模型。

推理强化学习

GRPO

蒸馏